

AFI ESCUELA DE FINANZAS

Máster en Data Science y Big Data en Finanzas



Afi Escuela
de Finanzas



**APLICACIÓN DE MODELOS DE MACHINE LEARNING SOBRE
UN PROBLEMA DE CLASIFICACIÓN DE CREDIT SCORING**

TRABAJO FIN DE MÁSTER

Eloy de la Rubia Luengo

Junio 2018

Tutores:

Ángel Bes Izuel (KPMG)

Borja Foncillas García (AFI)

PALABRAS CLAVE

Banca, Sector financiero, Riesgo de crédito, Credit Scoring, Modelo, Machine Learning, Clasificación, Regresión logística

TABLA DE CONTENIDO

1	Introducción	8
1.1	Resumen Ejecutivo	9
1.2	Objetivos.....	10
1.3	Estructura de la memoria	10
1.4	Tratamiento de los datos.....	11
2	Estado del arte.....	12
3	Diseño del modelo	15
3.1	Algoritmos estudiados.....	15
3.2	Definición de la variable dependiente.....	17
3.3	Origen de la información	18
3.4	Exclusiones de la Población Objetivo.....	19
3.5	Construcción de ratios	20
3.6	Modelado	21
3.6.1	Muestra de entrenamiento y test.....	21
3.7	Evaluación de modelos	23
3.7.1	Curva ROC	24
3.7.2	Sensibilidad y especificidad	25
4	Implementación práctica del modelo	27
4.1	Análisis exploratorio.....	27
4.1.1	Variable dependiente	27
4.1.2	Variables Independientes.....	28
4.1.3	Variables adicionales	43
4.2	Modelo base – Regresión Logística	44
4.2.1	Filosofía de segmentación para la construcción del modelo base	44
4.2.2	Variables finalistas del modelo base	47
4.3	Modelos avanzados	50
4.3.1	Mismas variables que el modelo base	50
4.3.2	Combinación de diferentes variables adicionales al modelo base	57

5	Resultados	75
6	Conclusiones	76
7	Trabajo futuro.....	77
8	Planificación.....	78
9	Anexo 1: tecnología utilizada.....	79
10	Bibliografía	80

ÍNDICE DE FIGURAS

FIGURA 3.1 - ENSEMBLE O SISTEMAS DE APRENDIZAJE MÚLTIPLES	17
FIGURA 3.2 - TMO EN EL HISTÓRICO DE LA CARTERA DE CONSUMO.....	18
FIGURA 3.3 - FLUJO DE TRABAJO DEL MODELO MACHINE LEARNING	21
FIGURA 3.4 - DIVISIÓN CONJUNTO DE DATOS (ESTRATIFICADA)	22
FIGURA 3.5 - CURVA ROC	24
FIGURA 4.1 - DEFAULT EN LA MUESTRA DE ENTRENAMIENTO	27
FIGURA 4.2 - DEFAULT EN LA MUESTRA DE TEST	28
FIGURA 4.3 - DISTRIBUCIÓN VARIABLE 1.....	29
FIGURA 4.4 - DISTRIBUCIÓN FDO RESPECTO LA VARIABLE 1	29
FIGURA 4.5 - DISTRIBUCIÓN VARIABLE 2.....	30
FIGURA 4.6 - DISTRIBUCIÓN FDO RESPECTO LA VARIABLE 2	30
FIGURA 4.7 - DISTRIBUCIÓN VARIABLE 3.....	31
FIGURA 4.8 - DISTRIBUCIÓN FDO RESPECTO LA VARIABLE 3.....	32
FIGURA 4.9 - DIAGRAMA DE VIOLÍN: INGRESOS VS. SITUACIÓN LABORAL	32
FIGURA 4.10 - DIAGRAMA DE VIOLÍN: INGRESOS VS. VARIABLE AUXILIAR DE CLIENTE	34
FIGURA 4.11 - DISTRIBUCIÓN VARIABLE 4.....	35
FIGURA 4.12 - DISTRIBUCIÓN FDO RESPECTO LA VARIABLE 4	35
FIGURA 4.13 - DISTRIBUCIÓN VARIABLE 5.....	37
FIGURA 4.14 - DISTRIBUCIÓN FDO RESPECTO LA VARIABLE 5	37
FIGURA 4.15 - IDENTIFICACIÓN DEL DEFAULT RESPECTO AL RATIO SALDO MEDIO PASIVO / IMPORTE DE LA OPERACIÓN	38
FIGURA 4.16 - DISTRIBUCIÓN VARIABLE 6.....	39
FIGURA 4.17 - DISTRIBUCIÓN FDO RESPECTO LA VARIABLE 6	39
FIGURA 4.18 - DISTRIBUCIÓN VARIABLE 7	40
FIGURA 4.19 - DISTRIBUCIÓN FDO RESPECTO LA VARIABLE 7	40
FIGURA 4.20 - IDENTIFICACIÓN DEL DEFAULT RESPECTO AL RATIO PLAZO / IMPORTE DE LA OPERACIÓN	41
FIGURA 4.21 - DISTRIBUCIÓN VARIABLE 7	42
FIGURA 4.22 - DISTRIBUCIÓN FDO RESPECTO LA VARIABLE 7	42
FIGURA 4.23 - DISTRIBUCIÓN VARIABLE 7 FINAL.....	43
FIGURA 4.24 - DISTRIBUCIÓN FDO RESPECTO LA VARIABLE 7	43
FIGURA 4.25 - GRÁFICO D LA CURVA ROC DEL MODELO BASE EN EL SET DE ENTRENAMIENTO (GLM)	48
FIGURA 4.26 - CORRELACIÓN V DE CRAMER ENTRE LAS VARIABLES INDEPENDIENTES DEL MODELO BASE	49
FIGURA 4.27 - GRÁFICO DE LA CURVA ROC DEL MODELO BASE EN EL SET DE TEST (GLM)	49
FIGURA 4.28 - GRÁFICO DE LA CURVA ROC DEL MODELO LDA EN EL SET DE ENTRENAMIENTO	51
FIGURA 4.29 - GRÁFICO DE LA CURVA ROC DEL MODELO LDA EN EL SET DE TEST	51
FIGURA 4.30 - GRÁFICO DEL ROC OBTENIDO RESPECTO AL NÚMERO DE VARIABLES DEL MODELO RF	53
FIGURA 4.31 - GRÁFICO DE LA CURVA ROC DEL MODELO RF EN EL SET DE ENTRENAMIENTO.....	53

FIGURA 4.32 - GRÁFICO DE LA CURVA ROC RESPECTO SUS PARÁMETROS EN EL MODELO ADA BOOST	57
FIGURA 4.33 - IMPORTANCIA DE LAS VARIABLES DEL MODELO RF EN BASE AL ÍNDICE DE GINI	58
FIGURA 4.34 - ROC ALCANZADO RESPECTO AL NÚMERO DE SELECTORES FIJADOS.....	59
FIGURA 4.35 - GRÁFICO RESULTADO DE LA ESTIMACIÓN ÓPTIMA Y AUTOMÁTICA DEL PARÁMETRO MTRY	60
FIGURA 4.36 - ROC VERSUS EL PARÁMETRO C (COMPLEJIDAD).....	61
FIGURA 4.37 - GRÁFICO DE LA CURVA ROC DEL MODELO RF EN EL SET DE TEST.....	62
FIGURA 4.38 - GRÁFICO DE LA CURVA ROC DEL MODELO GLMBOOST EN EL SET DE TEST.....	64
FIGURA 4.39 - GRÁFICO DE LA CURVA ROC RESPECTO SUS PARÁMETROS EN EL MODELO ADA BOOST	66
FIGURA 4.40 - GRÁFICO DE LA CURVA ROC DEL MODELO ADA BOOST EN EL SET DE TEST.....	67
FIGURA 4.41 - GRÁFICO DE LA CURVA ROC DEL MODELO DE RED NEURONAL EN EL SET DE TEST	70
FIGURA 4.42 - GRÁFICO DE LA CURVA ROC DEL MODELO XGBOOST EN EL SET DE TEST	72
FIGURA 4.43 - GRÁFICO COMPARATIVO DEL ROC SEGÚN EL MODELO DENTRO DEL ENSEMBLE	73
FIGURA 9.1 - ESPECIFICACIONES DEL HARDWARE Y EL SISTEMA OPERATIVO UTILIZADO.....	79

ÍNDICE DE TABLAS

TABLA 3.1 - MUESTRA DE ENTRENAMIENTO POR AÑO	22
TABLA 3.2 - MUESTRA DE TEST POR AÑO	23
TABLA 3.3 - MATRIZ DE CONFUSIÓN	24
TABLA 4.1 - CATEGORÍAS DE LA VARIABLE AUXILIAR 1.....	31
TABLA 4.2 - CATEGORÍAS DE LA VARIABLE AUXILIAR 2.....	31
TABLA 4.3 - DISTRIBUCIÓN FDO RESPECTO LA VARIABLE AUXILIAR DE CLIENTE.	33
TABLA 4.4 - DISTRIBUCIÓN FDO RESPECTO LA VARIABLE AUXILIAR 1	36
TABLA 4.5 - DISTRIBUCIÓN FDO RESPECTO LA VARIABLE AUXILIAR 2	36
TABLA 4.6 - EVALUACIÓN DEL MODELO LDA (ROC)	50
TABLA 4.7 - MATRIZ DE CONFUSIÓN DEL MODELO LDA	50
TABLA 4.8 - EVALUACIÓN DEL MODELO RF (ROC).....	52
TABLA 4.9 - EVALUACIÓN DEL MODELO SVM (ROC)	55
TABLA 4.10 - EVALUACIÓN DEL MODELO ADA BOOST (ROC)	56
TABLA 4.11 - EVALUACIÓN DEL MODELO RF (ROC).....	59
TABLA 4.12 - EVALUACIÓN DEL MODELO RPART (ROC).....	61
TABLA 4.13 - MATRIZ DE CONFUSIÓN DEL MODELO RPART	62
TABLA 4.14 - EVALUACIÓN DEL MODELO GLMBOOST (ROC).....	63
TABLA 4.15 - EVALUACIÓN DEL MODELO ADA BOOST (ROC)	65
TABLA 4.16 - MATRIZ DE CONFUSIÓN DEL MODELO ADA BOOST (ENTRENAMIENTO).....	66
TABLA 4.17 - MATRIZ DE CONFUSIÓN DEL MODELO ADA BOOST (TEST).....	67
TABLA 4.18 - EVALUACIÓN DEL MODELO GRADIENT BOOSTING (ROC).....	68
TABLA 4.19 - PARÁMETROS QUE HACEN ÓPTIMA LA RED NEURONAL	68

TABLA 4.20 - EVALUACIÓN DEL MODELO RED NEURONAL (1 CAPA) (ROC)	69
TABLA 4.21 - MATRIZ DE CONFUSIÓN DEL MODELO DE RED NEURONAL (TEST)	69
TABLA 4.22 - EVALUACIÓN DEL MODELO XGBOOST (ROC).....	71
TABLA 4.23 - MATRIZ DE CONFUSIÓN DEL MODELO XGBOOST (TEST)	71
TABLA 4.24 - EVALUACIÓN DEL MODELO ENSEMBLE PROPIO (ROC)	73
TABLA 4.25 - MATRIZ DE CORRELACIÓN DEL ENSEMBLE.....	74
TABLA 5.1 - TABLA COMPARATIVO DE MODELOS IMPLEMENTADOS	75
TABLA 8.1 - CALENDARIO DE TRABAJO.....	78
TABLA 8.2 - RECURSOS Y TIEMPO INVERTIDO	78

ÍNDICE DE ECUACIONES

ECUACIÓN 3.1 - AUC	25
ECUACIÓN 3.2 - RATIO DE PRECISIÓN (ACCURACY RATIO)	25
ECUACIÓN 3.3 - SENSIBILIDAD	25
ECUACIÓN 3.4 - ESPECIFICIDAD.....	26
ECUACIÓN 4.1 - WOE (WEIGHT OF EVIDENCE).....	44
ECUACIÓN 4.2 - IV (INFORMATION VALUE).....	45
ECUACIÓN 4.3 - COEFICIENTE DE PEARSON	46

1 INTRODUCCIÓN

Hoy en día, nos guste o no vivimos en una sociedad de consumo donde las entidades de crédito toman un papel relevante en la población. El ciclo de crédito al consumo está estrechamente vinculado con el consumo de las familias y sus hábitos; Es por ello, que las entidades de crédito están dispuestas a conceder crédito en cualquier momento del año, debido a que gran parte de su actividad se basa en la captación de depósitos y la concesión de préstamos, aunque no a cualquier precio.

Para que exista un correcto funcionamiento del ciclo de crédito al consumo, las entidades han de medir y gestionar de una manera adecuada los riesgos que ello implica. La complejidad en la gestión de estos riesgos ha aumentado durante los últimos años, lo cual ha generado importantes pérdidas económicas por parte de las instituciones financieras derivadas de fallos en los modelos de medición del riesgo. En especial, el riesgo de crédito supone una de las principales preocupaciones dentro de las entidades financieras. Para mitigar este tipo de riesgo, las entidades tienden a utilizar sistemas automáticos, *Credit Scoring* en adelante, que ayudan a puntuar a los clientes.

Los modelos de *Credit Scoring* son utilizados en multitud de decisiones (adquisición, comportamiento, valoración del riesgo, abandono, recobro, etc.) y sectores (banca, *utilities*, telcos, gran consumo, etc.). La tecnología analítica dominante en la actualidad es la regresión logística clásica; optimizada con el uso de variables mejoradas (transformaciones, *binning*, interacciones, combinaciones, etc.). Esta técnica es la más establecida por diferentes razones: sólida y rigurosa base científica, metodología de construcción bien establecida y probada, y principalmente por su facilidad de comprensión (facilidad para explicar y cuantificar la importancia y estabilidad de cada variable en el modelo).

Como resultado de la evolución tecnológica disruptiva en los últimos años, se han podido poner en marcha modelos avanzados de *Machine Learning*, que en gran parte de los problemas (clasificación y regresión) suponen una mejora sustancial. En este contexto, este trabajo tiene como fin analizar la posibilidad de aplicación de estas metodologías en la gestión del riesgo de crédito. Además, se estiman diversos modelos de *Credit Scoring* haciendo uso de algoritmos de *Machine Learning* y se realiza una comparación entre ellos. Por otro lado, se realiza un análisis comparativo entre la regresión logística, técnica tradicional del modelado del *Credit Scoring*, y los modelos de *Machine Learning* para identificar las ventajas e inconvenientes.

1.1 Resumen Ejecutivo

En el presente documento se expone una **comparativa de modelos de clasificación para estimar la calidad crediticia de los clientes** particulares de la cartera de consumo. La cartera de consumo empleada hace referencia a aquellos **clientes vinculados** con anterioridad a la solicitud del préstamo en una entidad bancaria nacional.

De cara a comprender las técnicas estándar del mercado en este tipo de problemas de clasificación de clientes, se desarrolla una regresión logística como la metodología base a batir por modelos avanzados de Machine Learning.

Por lo consiguiente, el estudio realizado constará de las siguientes fases:

1. Preprocesado de la información
 - a. Análisis exploratorio,
 - b. Tratamiento de *missings*,
 - c. Discretización de variables.
2. Construcción del modelo GLM (regresión logística)
 - a. Definición de la variable objetivo (Default / Incumplimiento)
 - b. Construcción del set de datos de entrenamiento y validación
 - c. Análisis exploratorio de las variables, discretización
 - d. Estimación de IV (*Information Value*)
 - e. Selección de variables
 - f. Modelización y resultados
3. Construcción de modelos avanzados de Machine Learning
 - a. Utilizando las mismas variables que el modelo GLM
 - b. Utilizando combinaciones de diferentes variables con las del modelo GLM
4. Comparativa de resultados
5. Conclusiones
6. Trabajo futuro

Debido al elevado número de variables disponibles y al coste de fases como el preprocesado de la información, su descripción se realizará a alto nivel, ya que el objetivo final del trabajo es el análisis comparativo de diferentes metodologías en la construcción de un modelo de Credit Scoring.

1.2 Objetivos

De acuerdo con el contexto descrito anteriormente, los principales objetivos del trabajo son:

- Estudiar el actual modelo de Credit Scoring de consumo existente en una entidad nacional y cuáles son sus motivaciones.
- Replicar y entender el actual modelo de Credit Scoring con la información proporcionada.
- En base a las variables finalistas del modelo de puntuación ya construido, probar otros tipos de modelos avanzados de ML.
- Estudiar otras posibles variables candidatas a utilizar en nuestros modelos.
- En base a las variables estudiadas, realizar un análisis comparativo respecto al modelo base (regresión logística) ya replicado.

Para llevar a cabo este trabajo se han utilizado los conocimientos obtenidos en los siguientes bloques del máster:

- Fundamentos de negocio bancario
- Programación en R y Python
- Estadística
- Tratamiento de Datos
- Visualización
- APIs
- Regresión avanzada mediante aprendizaje supervisado
- Modelos lineales generalizados
- Análisis discriminante lineal y no lineal
- Árboles de decisión y Random Forest

1.3 Estructura de la memoria

El trabajo se estructura en 7 secciones. En la primera de ellas (2. Estado del arte), se plantea el estado del arte en problemas de Credit Scoring. Se pretende saber qué es lo que se ha hecho hasta el momento y qué aporta este proyecto como novedad. En la segunda sección (3. Diseño del modelo) se lleva a cabo la descripción de los distintos algoritmos empleados, así como el conjunto de datos empleado. En la tercera sección (4. Implementación práctica del modelo) se describen las técnicas de modelización utilizadas,

desde el algoritmo base puesto a prueba, hasta las técnicas más avanzadas de Machine Learning. En la cuarta sección (5. Resultados) se presentan los resultados y se comparan las distintas técnicas empleadas en el paso anterior. En la quinta sección (6. Conclusiones), se describen las conclusiones obtenidas tras la realización del proyecto. En la sexta sección (7. Trabajo futuro) se enumeran algunas mejoras y líneas de investigación futura. Por último, se describe la planificación del trabajo realizado (8. Planificación).

1.4 Tratamiento de los datos

Debido a la sensibilidad de los datos aportados, es importante indicar que la información presente en el documento puede haber sufrido algún tipo de enmascaramiento, de tal forma que se preserve la confidencialidad de los clientes y datos sensibles involucrados en el estudio.

2 ESTADO DEL ARTE

En los últimos años, y gracias los avances tecnológicos existentes en la ciencia computacional y de la información, se ha potenciado la búsqueda de herramientas y desarrollo de nuevas metodologías de trabajo que mejoren y faciliten la realización de actividades relacionadas con la explotación, tratamiento, análisis de la información y toma de decisiones en una multitud de campos del conocimiento. De este modo, se están realizando grandes avances dirigidos a mejorar el entendimiento de patrones en base a los datos, lo cual conlleva a mejoras en la toma de decisiones (entre otras, mayor objetividad y predictividad) en campos dispares como la economía, la medicina, el marketing, la educación o la gestión pública y empresarial.

Estos avances tecnológicos están beneficiando a prácticamente la totalidad de los sectores, aunque de manera bastante heterogénea. Entre otros, el sector financiero va un paso por detrás en la implantación de estos avances, debido en gran parte, a la regulación existente bajo la que queda amparado. No obstante, la banca y el regulador están trabajando en nuevas líneas de actuación basadas en gran parte de estos avances tecnológicos, que favorecen la aplicación de técnicas de *Machine Learning* (ML) o aprendizaje automatizado para identificar, cuantificar y mitigar, de la manera más eficaz posible los riesgos a los que se ve sometido.

La explotación de estas técnicas surge como consecuencia de diversos factores: la cantidad de información disponible es superior que hace unos años y de mayor calidad, los cambios socioeconómicos ocurren con mayor frecuencia y la demanda de crédito es cambiante. De esta forma, se intentan crear modelos con mayor vigencia, con mayor poder predictivo (mayor tasa de acierto y menor error) y con bajos costes por parte de la entidad.

Sin embargo, el *Machine Learning* no es un concepto nuevo, sino que sus orígenes se remontan a mediados del siglo XX, cuando el matemático Alan Turing, considerado uno de los padres de la ciencia de la computación y precursor de la informática moderna, crea el “Test de Turing” [1]. Desde 1950 este campo ha sufrido grandes altibajos, dándose su gran explosión y puesta comercial en 2006. Este gran boom fue, debido en gran parte, al aumento de la potencia de cálculo y la gran abundancia de datos disponibles. El *Machine Learning* es, sin duda, uno de los conceptos de moda dentro del mundo del *Big Data* y de la inteligencia artificial.

Centrándonos en la gestión de riesgos dentro de las entidades financieras, el principal riesgo que deben de afrontar es el riesgo de crédito, definido por el Banco de España [2]

(BdE), como el riesgo de que una entidad de contrapartida no atienda una obligación de pago en su totalidad, ya sea al vencimiento o en cualquier momento posterior.

En su origen, el analista experto era el encargado de gestionar este riesgo y tomar la decisión, basándose en reglas de negocio y su *expertise*, sobre que préstamos se concedían y cuáles no. Con la introducción de estos sistemas en la gestión del riesgo de crédito de las entidades, la toma de decisiones fue automatizándose y ayudando a la gestión del riesgo de una manera más eficaz y eficiente. Con la llegada de avances tecnológicos y la mayor disposición de grandes cantidades de datos, se abre una nueva era donde las técnicas de inteligencia artificial y *Machine Learning* toman gran relevancia en el avance de este tipo de herramientas.

No obstante, la aplicación de dichas técnicas avanzadas aún debe de afrontar diversos desafíos, sobre todo en el ámbito regulatorio, el principal causante del letargo de estas herramientas en el mundo financiero. Sumado a la normativa ya vigente, la entrada de la nueva regulación de protección de datos RGPD [3] (Reglamento General de Protección de Datos) complica aún más la utilización de estas herramientas en la gestión del riesgo, ya que otorga a los interesados el derecho a la explicación de la decisión tomada mediante cualquier algoritmo o sistema automatizado. Como se sostiene en un análisis de la RGPD [4]: *“es lógico que un algoritmo sólo pueda ser explicado si el modelo entrenado puede ser expresado y entendido por una persona”*, lo cual entra en conflicto con la naturaleza de gran parte de los modelos complejos de *Machine Learning*, conocidos por su poca interpretabilidad como Cajas Negras [5].

Respecto a la regulación europea bajo la que queda amparado el sector financiero para la regulación de modelos de admisión de crédito, conocida como CRR [6] (*Capital Requirements Regulation*), se establece que las entidades financieras deberán de contar con procedimientos que garanticen la completitud, precisión, consistencia y trazabilidad de los datos. Además, hace referencia a la construcción de modelos parsimoniosos, es decir, modelos no muy complejos y explicables. Es por ello por lo que, tanto en la trazabilidad de la información, como a la hora de explicar el funcionamiento de los datos dentro de este tipo de modelos, supone un gran inconveniente para la implantación de modelos de *Machine Learning*.

Por todo ello, hoy en día la implantación y automatización de técnicas complejas de ML no son posibles en las entidades sin la figura del analista en la toma de decisión final. No obstante, queda cabida para su utilización como herramienta de gestión del riesgo, dando soporte al especialista en la elección de la mejor decisión.

Respecto al estudio del uso de algoritmos avanzados de ML o herramientas de aprendizaje automático para la puntuación de clientes, se remonta a principios de la última década, donde se ha tratado de batir el modelo “tradicional” (regresión logística) con la utilización de estos algoritmos, llegando a diversas conclusiones. Según un estudio realizado en 2013 [7], donde se compararon 41 algoritmos diferentes de clasificación que podrían ser utilizados en modelos de Scoring, una de las principales conclusiones obtenidas fue que la regresión logística sigue siendo el estándar de mercado por predictividad y simplicidad, aunque se lograra batir su predicción ligeramente con otro tipo de algoritmos más sofisticados como *Random Forest*.

Existen diversos estudios sobre la materia [8] [9] [10] [11], como el de David West [12], el cual compara el comportamiento de cinco redes neuronales distintas con el comportamiento de los modelos estándar del mercado (LDA, regresiones logísticas, vecinos próximos y árboles de decisión). En este artículo, asegura que *Lloyds Bank* está actualmente utilizando un modelo de Scoring basado en redes neuronales un 10% más preciso que su predecesor. También afirma que el *Security Pacific Bank* (SPB) está utilizando una red neuronal multiperceptrón para sus modelos de Scoring, y que cualquier pequeño beneficio que obtengan en las predicciones les puede suponer millones de dólares de beneficio. No obstante, la utilización de algoritmos avanzados de ML no funciona igual de bien en todos sus modelos, y destaca que la regresión logística sigue siendo el referente en promedio a batir.

En resumen, si bien el sistema financiero vive en un entorno prolífero para el desarrollo de técnicas de *Machine Learning*, donde existe una mayor disponibilidad de datos a un menor coste, la regulación vigente limita el uso exclusivo y autónomo de estas técnicas, lo que sitúa al ML como herramienta de soporte en procesos regulados o aspectos concretos no regulados (ej. detección de fraude).

3 DISEÑO DEL MODELO

En este apartado se describen algunos de los algoritmos estudiados, así como el origen de la información, la división de muestras e información relevante sobre la variable objetivo.

3.1 Algoritmos estudiados

Tras el estudio de las tendencias de mercado (2 Estado del arte) que se están aplicando en modelización de Credit Scoring con métodos estándar y de *Machine Learning*, vamos a realizar una breve descripción de algunos de los algoritmos estudiados:

- a) **Regresión Logística (GLM):** La regresión logística es un modelo de clasificación lineal, en concreto se trata de un modelo lineal generalizado (GLM), que usa como función de enlace la función *logit*. Puede servir para clasificar de forma binaria o en más de una clase. Es útil para estimar la probabilidad de que un evento suceda en función de variables predictoras. Funciona bastante bien con muestras no balanceadas (como el caso bajo estudio) y sus salidas son fácilmente interpretables.
- b) **Análisis Discriminante Lineal (LDA):** Es un método de clasificación supervisado de variables cualitativas en el que dos o más grupos son conocidos a priori y nuevas observaciones se clasifican en uno de ellos en función de sus características. Haciendo uso del teorema de Bayes, LDA estima la probabilidad de que una observación, dado un determinado valor de los predictores, pertenezca a cada una de las clases de la variable cualitativa, $P(Y=k | X=x)$. Finalmente se asigna la observación a la clase k para la que la probabilidad predicha es mayor. Es una alternativa a la regresión logística cuando la variable cualitativa tiene más de dos niveles.
- c) **Análisis Discriminante cuadrático (QDA):** Se asemeja en gran medida al LDA, con la única diferencia de que el QDA considera que cada clase k tiene su propia matriz de covarianza (Σ_k) y, como consecuencia, la función discriminante toma forma cuadrática. QDA genera límites de decisión curvos por lo que puede aplicarse a situaciones en las que la separación entre grupos no es lineal.
- d) **Random Forest (RF):** Es un algoritmo de *bagging*, que se basa en la generación de árboles de clasificación aleatorios con muestreo por *bootstrapping*, obteniendo los resultados de la clasificación promediando los resultados individuales de cada árbol. Tiene la característica de que cada vez que se va a realizar un corte en un nodo, en lugar de evaluar todas las variables disponibles, se evalúa únicamente un subconjunto aleatorio de ellas. Tiene como punto débil su dificultad de ser interpretado (podemos decir que es un modelo “caja negra”).

- e) **Máquinas de Vector Soporte (SVM):** Una SVM es un modelo que representa a los puntos de muestra en el espacio, separando las clases a 2 espacios lo más amplios posibles mediante un hiperplano de separación definido como el vector entre los 2 puntos, de las 2 clases, más cercanos al que se llama vector soporte. Cuando las nuevas muestras se ponen en correspondencia con dicho modelo, en función de los espacios a los que pertenezcan, pueden ser clasificadas a una o la otra clase.
- f) **Redes Neuronales (RNN):** De forma muy resumida, podemos decir que las redes neuronales están formadas por un conjunto de perceptrones interconectados en capas, de forma similar a las conexiones presentes en un cerebro biológico. Cada una de estas neuronas está conectada con otras y los enlaces entre ellas pueden incrementar o inhibir el estado de activación de las neuronas adyacentes. Mediante la *retropropagación* o propagación hacia atrás, aprenden de forma supervisada, reajustando iterativamente el peso de cada neurona para reducir el error cometido en la salida del algoritmo. Las redes neuronales pueden utilizar métodos de regularización (para evitar el sobreajuste), como el *Dropout*, que consisten en eliminar neuronas de forma aleatoria en cada una de las iteraciones de ajuste.
- g) **Naive Bayes (NB - Gaussiana):** Clasificador basado en el teorema de Bayes, que asumen una fuerte independencia entre las variables del modelo. Es decir, Naive Bayes asumen que cada variable contribuye independientemente a la variable objetivo, sin tener en cuenta correlaciones con las otras variables. Se trata de un algoritmo altamente escalable y que, en muchos casos, se entrena mediante máxima verosimilitud, lo que lo convierte en un modelo que se entrena relativamente rápido (en comparación con otras técnicas de aprendizaje automático). Suele usarse mucho en clasificación de textos.
- h) **Ada Boost (ADA):** Se basa en el ensamblado de varios clasificadores débiles, similar al algoritmo Random Forest (cuando estos clasificadores son árboles). A cada uno de estos clasificadores débiles se les asigna un peso, que se irá adaptando de forma iterativa mediante un algoritmo de optimización, hasta conseguir la configuración de pesos óptima que minimiza el error de entrenamiento. Es sensible a datos erróneos u outliers, por lo que el preprocesado de los datos es muy importante.
- i) **Gradient Boosting (GBM) y Extreme Gradient Boosting (XGB):** Se trata de otros dos métodos de Ensemble de clasificadores débiles, podrían considerarse como la continuación a ADA Boost, Se caracterizan, entre otras cosas, por su algoritmo de optimización de descenso por gradiente, usado para minimizar la función de pérdidas.

- j) **Ensembles:** Utilizan múltiples algoritmos de aprendizaje para obtener un rendimiento predictivo que mejore el que podría obtenerse por medio de cualquiera de los algoritmos de aprendizaje individuales que lo constituyen. La idea de los métodos combinados es considerar múltiples hipótesis simultáneamente para formar una hipótesis que, con suerte, se comporte mejor. El término de métodos de Ensemble se suele reservar para aquellas combinaciones que hacen uso de múltiples hipótesis pertenecientes a una misma familia, mientras que se usa el término más general de sistemas de aprendizaje múltiples cuando las hipótesis que se combinan provienen de diversas familias.




Figura 3.1 - Ensemble o sistemas de aprendizaje múltiples

3.2 Definición de la variable dependiente

El comportamiento de impago se mide a través de una variable que señala si una operación se encuentra en situación de incumplimiento (DEFAULT).

Para que una operación sea considerada en incumplimiento deberá cumplir las siguientes condiciones:

- La operación ha estado en situación de impago para la materialidad definida más de 90 días seguidos, se encuentra en mora subjetiva o bien cumple las características del marcaje como mala de una operación refinanciada.
- La materialidad del impago es mayor que 1 euro a nivel operación.

Dichas conclusiones fueron fruto del consenso entre los diferentes departamentos involucrados en base a las distintas pruebas realizadas, a los análisis de las tasas de mora para distintos periodos de comportamiento y a la valoración de la duración del periodo de maduración.

A continuación, se grafica las tasas de mora observadas en los diferentes años para operaciones de consumo que pasan los filtros de exclusiones iniciales.




Figura 3.2 - TMO¹ en el histórico de la cartera de Consumo

3.3 Origen de la información

Los modelos generados están basados en información de los titulares e información de la operación en el momento de concesión, con el objetivo de asignar una puntuación a cada operación a partir de la cual decidir sobre la admisión o no de la misma. El público con el que se modela y al que va dirigido el modelo de calificación son las operaciones de préstamo al consumo de clientes vinculados con la entidad bancaria, excluyendo las dirigidas a la compra de vivienda.

Para construir los modelos cuantitativos se han empleado datos desde enero del año x a junio del año $x+8$. Para las operaciones con plazo igual o inferior a 48 meses, se ha considerado como periodo de observación el periodo comprendido desde enero del año x a junio del año $x+6$, incluyéndose además las operaciones que están en default de julio de $x+6$ a junio de $x+8$ por considerarse ya operaciones maduras. Por otro lado, para las operaciones con plazo superior a 48 meses, se ha considerado como periodo de observación el periodo comprendido desde enero del año x a diciembre de $x+5$, incluyéndose además las operaciones que están en default de enero de $x+6$ a junio de $x+8$ por considerarse ya operaciones maduras.

Se considera como periodo de comportamiento, el periodo entre la formalización de los contratos y junio de $x+8$. Se han definido dos periodos mínimos de observación en función del plazo de la operación:

¹ TMO (*Tasa de Mora Observada*): Número de malos entre el total (malos + buenos) de la muestra.

- Para préstamos con vencimientos menores o iguales a 4 años, el periodo mínimo de observación es de 24 meses.
- Para préstamos con vencimientos mayores a 4 años, el periodo mínimo de observación es de 30 meses.

A partir de diferentes tablas del sistema informacional de la Entidad, se ha creado un tablón a nivel operación con todas las variables que se han considerado oportunas, tanto por el equipo de desarrollo del modelo como por parte del área de negocio de la entidad. Las tablas origen de datos contienen la siguiente información:

- Intervinientes:** tanto de los titulares como de los avalistas del préstamo de consumo. (situación laboral, ingresos, ...).
- CIRBE**
- Comportamiento:** información del comportamiento de pago de los intervinientes (identificadores de si los intervinientes aparecen en las bases de datos internas de morosidad o de seguimiento del riesgo de crédito y el importe total en impago del titular en bases externas de morosidad).
- Operación:** relativa a las características de la operación de consumo (importe, finalidad, ...).
- Políticas:** relativa a variables empleadas en las políticas actuales de la entidad.
- Incidencias:** para la construcción de la variable objetivo (DEFAULT) (Duración, motivo de mora...).
- Refinanciaciones:** Contiene la información de las operaciones refinanciadas.
- Empleados:** relativa a variables de expedientes tales como el indicador de empleado.
- Vinculación:** información de la relación que mantienen los intervinientes con la entidad.

A partir de este tablón de información agregada, se ha realizado una limpieza exhaustiva de los datos, se han excluido ciertas muestras y se han corregido datos que no eran correctos. A partir de aquí, se han construido ratios y se han seleccionado las variables candidatas a formar parte del modelo base siguiendo los criterios que se explicarán a continuación.

3.4 Exclusiones de la Población Objetivo

Se han eliminado de la muestra de construcción:

- Las operaciones denegadas dado que no es posible conocer el comportamiento de las mismas.
- Los créditos al consumo debido a la diferencia en el comportamiento con respecto a los préstamos al consumo y al reducido volumen de éstos.
- Las refinanciaciones, ya que la naturaleza y comportamiento de estas operaciones es totalmente diferente a las operaciones de admisión.
- Los préstamos al consumo con finalidad “Compra de vivienda” han sido eliminados de la muestra debido a que el comportamiento de los mismos difiere de los préstamos al consumo con una finalidad significativamente diferente al resto y su comportamiento se asemeja al de los préstamos hipotecarios según negocio.

3.5 Construcción de ratios

Se parte de más de **260 variables**, de las cuales, más de 150 son ratios contruidos divididos en 6 bloques de información:

- Módulo **CIRBE**: Estas variables valoran las posiciones en los distintos productos que el cliente tiene en todas las entidades financieras del país, la proporción de esas posiciones que están en la entidad, así como los impagos y su cuantía.
- Módulo de **comportamiento de pago**: Estos ratios valoran la capacidad del pago del cliente en base a sus ingresos, así como su comportamiento de pago en otros productos de la entidad en base a sus impagos.
- Módulo datos **laborales/socioeconómicos**: Estos ratios aportan información personal y laboral acerca de los titulares de la operación para conocer la situación de los mismos.
- Módulo **endeudamiento/solvencia**: Estos ratios valoran el endeudamiento de los titulares que solicitan la operación, así como su solvencia para analizar la capacidad de éstos para hacer frente al pago de las cuotas del préstamo de consumo solicitado.
- El módulo **operación**: Estos ratios aportan información de las características de la operación solicitada tales como el plazo, el importe, la finalidad, el canal por el que se ha solicitado la operación...
- El módulo **vinculación** valorará la capacidad predictiva de 24 ratios.

3.6 Modelado

En el proceso de construcción de un modelo se debe utilizar una estrategia para que el sistema de clasificación sea lo más óptimo y robusto posible. Aunque los argumentos del modelado de este trabajo se vean en detalle más adelante, funcionalmente se comportan de una forma similar a la definida a continuación.




Figura 3.3 - Flujo de trabajo del modelo Machine Learning

3.6.1 Muestra de entrenamiento y test

Una vez construido el set de datos de partida, es necesario proceder a la partición de la muestra para obtener una muestra de entrenamiento (desarrollo) y otra de test. La muestra de entrenamiento (*train*) se usará para ajustar el modelo y la muestra de test se usará para comprobar que los resultados obtenidos en el entrenamiento del modelo son correctos (similares).

El objetivo de esta partición es desarrollar modelos que puedan aplicarse adecuadamente a nuevos casos, distintos de los utilizados para el desarrollo. En efecto, si toda la muestra de análisis se utilizara para ajustar los modelos, se podría llegar a modelos que separasen muy bien las operaciones buenas de las malas, pero no se tendría la garantía de que los resultados fueran similares a la hora de aplicar dichos modelos a nuevos casos.

La partición está estratificada por la variable objetivo (DEFAULT), de forma que la proporción de operaciones Buenas y Malas en cada conjunto se mantenga. Matizar que el

porcentaje empleado para la partición de la muestra ha sido del 80% para entrenamiento y un 20% para test.




Figura 3.4 - División conjunto de datos (Estratificada)

Entre los dos enfoques de selección *out of time* y *out of sample* para las muestras de desarrollo y test, se elige para este ejercicio, la utilización de muestras *out of sample* es decir, ambas muestras pertenecen al mismo periodo de tiempo.

Es relevante destacar que, dada la naturaleza aleatoria de este ejercicio de partición, para la replicación del mismo, se ha guardado la semilla que identifica las muestras para permitir su réplica, la semilla definida en este ejercicio es 5555.

Los conjuntos de entrenamiento y test quedan compuestos de la siguiente manera:

- **Muestra de entrenamiento:** incorpora 34.229 observaciones buenas y 2.290 observaciones morosas, con un total de **36.519 observaciones**.

ENTRENAMIENTO					
AÑO	BUENO	MOROSO	TOTAL	Tasa de Mora	% Población
x	9.822	733	10.555	6,94%	28,90%
x+1	8.037	372	8.409	4,42%	23,03%
x+2	6.226	333	6.559	5,08%	17,96%
x+3	4.747	290	5.037	5,76%	13,79%
x+4	3.974	240	4.214	5,70%	11,54%
x+5	1.423	195	1.618	12,05%	4,43%
x+6	0	124	124	100,00%	0,34%
x+7	0	3	3	100,00%	0,01%
Total	34.229	2.290	36.519	6,27%	80,00%

Tabla 3.1 - Muestra de entrenamiento por año

- **Muestra de test:** incorpora 8.557 observaciones buenas y 573 observaciones, con un total de **9.130 observaciones**.

TEST					
AÑO	BUENO	MOROSO	TOTAL	Tasa de Mora	% Población
x	2.320	182	2.502	7,27%	27,40%
x+1	2.038	102	2.140	4,77%	23,44%
x+2	1.614	88	1.702	5,17%	18,64%
x+3	1.253	64	1.317	4,86%	14,42%
x+4	963	62	1.025	6,05%	11,23%
x+5	369	36	405	8,89%	4,44%
x+6	0	39	39	100,00%	0,43%
x+7	0	0	0		
Total	8.557	573	9.130	6,28%	20,00%

Tabla 3.2 - Muestra de test por año

Como se puede observar en ambas muestras, para los años x+6 y x+7 únicamente tenemos en la muestra los sujetos que han impagado, ya que las operaciones aprobadas en ese periodo no tienen la madurez suficiente para considerarlas como buenas.

3.7 Evaluación de modelos

Tras el proceso de entrenamiento resulta indispensable el poder estimar la calidad del modelo que hemos construido.

En nuestro caso de estudio (Credit Scoring), el objetivo consiste en clasificar a los clientes en dos categorías, 'buenos' (no hacen default) o 'malos' (hacen default). No obstante, algunos clientes buenos serán clasificados como malos (error de tipo II) y habrá casos de clientes malos que serán clasificados como buenos (error de tipo I). De esta manera, el mejor modelo será aquel que consiga minimizar estos errores. En el caso de nuestro problema de Credit Scoring, la gestión de estos errores es un punto crítico que debe gestionar la entidad según su plan estratégico, ya que, los errores de tipo I suponen un incremento de la cartera morosa y los errores de tipo II suponen una pérdida de oportunidad.

Para poder estimar cuál de los modelos desarrollados es el mejor, existen varias métricas de evaluación. A continuación, se describen los métodos de evaluación utilizados a lo largo del trabajo para calificar los modelos.

Antes de estudiar las diferentes métricas de evaluación, es indispensable definir la matriz de confusión, herramienta gráfica que permite la visualización del desempeño de un algoritmo que se emplea en aprendizaje supervisado. Esta herramienta enfrenta los casos

reales frente a los predichos, arrojando información sobre los éxitos y fracasos en la predicción de los datos.

Predicción	Referencia	
	NO	SI
NO	TN	FN
SI	FP	TP

Tabla 3.3 - Matriz de confusión

Donde,

- *True Positive* (TP): Número de predicciones correctas de que una instancia es positiva.
- *True Negative* (TN): Número de predicciones correctas de que una instancia es negativa.
- *False Positive* (FP): Número de predicciones incorrectas de que una instancia es positiva.
- *False Negative* (FN): Número de predicciones incorrectas de que una instancia es negativa.

Nuestra matriz de confusión arroja unas dimensiones 2x2 debido a que nuestro problema de clasificación es binario. No obstante, si nos enfrentásemos a un problema de clasificación con n clases, nuestra matriz tendría unas dimensiones de $n \times n$.

3.7.1 Curva ROC

El análisis de curvas ROC constituye una de las formas más eficaces y utilizadas en la evaluación del rendimiento de un modelo orientado a la clasificación binaria. La curva ROC (*Receiver Operation Characteristic*) representa la tasa de verdaderos positivos (Sensibilidad) en el eje vertical en función de la tasa de falsos positivos ($1 - \text{Especificidad}$) en el eje horizontal para diferentes puntos de corte.




Figura 3.5 - Curva ROC

La medida ROC es, por tanto, el área que se encuentra por debajo de la Curva ROC, es decir:

$$A = \int_0^1 HR(FAR)d(FAR)$$

Ecuación 3.1 - AUC

Donde,

- *HR*: Es el porcentaje estimado de default, que ha sido clasificado correctamente (Sensibilidad).
- *FAR*: Es el porcentaje de cumplidores (buenos), que se habían clasificado incorrectamente como incumplidores (malos), es decir, 1-Especificidad.

Asimismo, esta medida puede ser expresada como transformación lineal de la medida anterior, el Ratio de Precisión (*Accuracy Ratio*):

$$AR = 2A - 1$$

Ecuación 3.2 - Ratio de Precisión (Accuracy Ratio)

Donde,

- *A*: Es el área que se encuentra por debajo de la curva ROC

3.7.2 Sensibilidad y especificidad

Encontrar un clasificador adecuado no sólo implica la obtención un ROC alto, sino también un equilibrio entre las predicciones conservadoras y agresivas. Para identificar este balance, existen las medidas de sensibilidad y especificidad.

La sensibilidad de un modelo (*S*) mide la proporción de casos positivos que sido clasificado correctamente.

$$S = \frac{TP}{TP + FN} \quad S \in [0, 1]$$

Ecuación 3.3 - Sensibilidad

La especificidad del modelo (*E*) mide la proporción de casos negativos que han sido clasificados correctamente.

$$E = \frac{TN}{TN + FP} \quad E \in [0, 1]$$

Ecuación 3.4 - Especificidad

El valor ideal para ambos casos sería lo más cerca posible del 1, pero es importante el balance entre ambos valores. Como hemos mencionado con anterioridad, es la entidad en nuestro caso quien decide el riesgo a asumir y hacia qué lado de la balanza se posiciona.

4 IMPLEMENTACIÓN PRÁCTICA DEL MODELO

Una vez unificada y tratada la información que disponemos, y definido el objetivo del trabajo, procedemos a describir el desarrollo del mismo. Como hemos comentado anteriormente, lo dividiremos en varias partes:

- a) Análisis exploratorio.
- b) Desarrollo del modelo base (regresión logística).
- c) Modelos avanzados.
 - a. Variables modelo base.
 - b. Otras variables.

4.1 Análisis exploratorio

4.1.1 *Variable dependiente*

Como ya hemos definido anteriormente en el apartado 3.2 *Definición de la variable objetivo (Default / Incumplimiento)*, nuestra variable objetivo del modelo es el **DEFAULT**, también conocido como **Incumplimiento**. Esta variable dicotómica, toma valores 0 o 1 para indicar si no se ha dado el incumplimiento, o si, respectivamente.

Se puede observar en los siguientes gráficos que nos encontramos con una muestra muy desbalanceada, donde el incumplimiento se sitúa en torno al 6% de los casos respecto al total de la muestra. Este tipo de muestras desbalanceadas en problemas de Credit Scoring es lo habitual, ya que, en caso contrario, la entidad dejaría de ser rentable debido al no retorno del capital prestado, algo impensable para la supervivencia de los bancos.




Figura 4.1 - Default en la muestra de entrenamiento




Figura 4.2 - Default en la muestra de test

4.1.2 Variables Independientes

Como hemos comentado con anterioridad, al disponer de un número elevado de variables, y alguna de ellas contener datos sensibles, vamos a realizar un análisis exploratorio de las variables más relevantes.

4.1.2.1 Variable1

Esta variable categórica ha sido construida en base a una variable numérica, la cual recoge información sobre evaluaciones del cliente, que tiene pendientes el cliente. Los tramos creados han sido tres, de los cuales uno no está presente debido a no existir valores *missings*.

Se puede observar que los dos tramos se diferencian significativamente en la **FDO** (Frecuencia de Default Observada), la cual identifica el porcentaje de malos (defaults) entre el total de la muestra. Además, se identifica que está alineada con el negocio, es decir, cuanto mayor número de operaciones tiene un cliente, mayor es Default observado.




Figura 4.3 - Distribución Variable 1




Figura 4.4 - Distribución FDO respecto la Variable 1

4.1.2.2 Variable 2

Esta variable categórica es el resultado de la combinación de una variable numérica relacionada con ingresos con una variable categórica que recoge información de recibos del cliente




Figura 4.5 - Distribución Variable 2




Figura 4.6 - Distribución FDO respecto la Variable 2

4.1.2.3 Variable3

La Variable 3 es una variable categórica resultado de la combinación de otras dos variables categóricas, ambas relacionadas con características de la finalidad del préstamo.

La finalidad del préstamo puede tomar las siguientes categorías:

DESCRIPCION	TRAMOS	FDO	% pob
Finalidad 1	5	2,32%	9,66%
Finalidad 2	3	3,66%	0,67%
Finalidad 3	2	4,38%	0,38%
Finalidad 4	1	4,67%	23,42%
Finalidad 5	8	4,76%	0,17%
Finalidad 6	6	5,56%	23,44%
Finalidad 7	4	5,88%	0,37%
Finalidad 8	7	8,54%	41,89%

Tabla 4.1 - Categorías de la variable auxiliar 1

En cuanto a la otra variable auxiliar utilizada, puede tomar los siguientes dos valores:

DESCRIPCION	TRAMOS	FDO	% pob
Característica 1	1	2,95%	42,74%
Característica 2	2	5,94%	57,26%

Tabla 4.2 - Categorías de la variable auxiliar 2

Tras la combinación de ambas variables, hemos obtenido los siguientes tres tramos:




Figura 4.7 - Distribución Variable 3




Figura 4.8 - Distribución FDO respecto la Variable 3

4.1.2.4 Variable 4

Esta variable categórica es resultado de la combinación de tres variables, una variable numérica relacionada con ingresos del cliente y dos variables categóricas relacionadas con características del cliente como la situación laboral.




Figura 4.9 - Diagrama de violín: Ingresos vs. Situación laboral

Tras el estudio del gráfico de violín anterior, se denota que los ingresos de los casos en incumplimiento se concentran en rangos inferiores. En cuanto a la situación laboral 'Fijo', se visualiza claramente que es donde mayor población existe, lo cual, tiene bastante sentido, ya que nos dice que la mayor parte de las operaciones aprobadas han sido a clientes con ingresos fijos recurrentes. También se puede observar, cómo según la situación laboral, el violín se estira o se encoge, dando a conocer que el rango de los ingresos fijos es más amplio y heterogéneo, o, al contrario.

Para los casos anteriores con situación laboral *missing* u Otros, se ha utilizado la combinación de otra característica del cliente. Tras el análisis, hemos podido observar que gracias a la ausencia de valores *missings*, todos los registros hacen referencia a la Situación laboral igual a 'Otros'.

DESCRIPCION	TRAMOS	TMO	%pob
Característica 1	1	3,56%	6,76%
Característica 2	2	4,95%	8,34%
Característica 3	3	5,00%	0,34%
Característica 4	4	5,12%	71,93%
Característica 5	5	14,62%	12,47%
Característica 6	6	22,22%	0,15%

Tabla 4.3 - Distribución FDO respecto la variable auxiliar de cliente.

En el siguiente Diagrama de violín podemos observar la distribución de los ingresos según la variable auxiliar de cliente. Mencionar que el orden es de menor a mayor de izquierda a derecha separado en aquellos casos de los que no incumplen (izquierda) y los que incumplen (derecha)




Figura 4.10 - Diagrama de violín: Ingresos vs. Variable auxiliar de cliente

En el gráfico de violín anterior, podemos observar para aquellas operaciones con situación laboral 'Otros' o 'Missing', como se concentra mayor población en la característica 5, correspondiendo esta con uno de los tramos con mayor probabilidad de incumplimiento, lo cual tiene sentido económico.




Figura 4.11 - Distribución Variable 4




Figura 4.12 - Distribución FDO respecto la Variable 4

4.1.2.5 Variable 5

La Variable 5 es una variable categórica combinación de, una primera variable discreta relacionada con características del cliente y una segunda variable relacionada con características de la vivienda.

La primera variable relacionada con características del cliente es una variable discreta que contiene 7 categorías diferentes:

DESCRIPCION	TRAMOS	TMO	% pob
Categoría 1	2	5,21%	47,70%
Categoría 2	4	5,61%	4,15%
Categoría 3	1	6,97%	38,33%
Categoría 4	5	8,19%	4,18%
Categoría 5	3	8,87%	0,34%
Categoría 6	6	9,26%	4,76%
Categoría 7	7	12,69%	0,54%

Tabla 4.4 - Distribución FDO respecto la variable auxiliar 1

La variable relacionada con características de la vivienda es una variable categórica que toma los siguientes 6 valores diferentes:

DESCRIPCION	TRAMOS	TMO	% pob
Característica 1	1	4,07%	21,67%
Característica 2	2	5,39%	37,16%
Característica 3	3	5,85%	3,09%
Característica 4	5	6,59%	15,79%
Característica 5	6	7,98%	10,33%
Característica 6	4	11,22%	11,96%

Tabla 4.5 - Distribución FDO respecto la variable auxiliar 2

A continuación, se puede observar la distribución de esta variable con el porcentaje de casos Default correspondiente. Además, se visualiza con una línea roja la FDO, la cual tiene una tendencia creciente continua y está alineada con el sentido económico.




Figura 4.13 - Distribución Variable 5




Figura 4.14 - Distribución FDO respecto la Variable 5

4.1.2.6 Variable 6

Ratio que relaciona el sumatorio del saldo medio pasivo con el importe del crédito.

Si observamos el comportamiento del saldo pasivo con el importe de la operación, observamos que los defaults suelen estar situados en el centro de la nube de puntos.




Figura 4.15 - Identificación del Default respecto al ratio Saldo medio pasivo / Importe de la operación

Si estudiamos el comportamiento del ratio anterior y tratamos de discretizarlo de forma que la FDO tenga una tendencia continua, obtenemos los siguientes *buckets*.




Figura 4.16 - Distribución Variable 6




Figura 4.17 - Distribución FDO respecto la Variable 6

4.1.2.7 Variable 7

Esta variable categórica es una variable dicotómica relacionada con la morosidad anterior del cliente.

Se puede observar claramente que, si se activa el indicador, su probabilidad de Default se incrementa significativamente (x3).




Figura 4.18 - Distribución Variable 7




Figura 4.19 - Distribución FDO respecto la Variable 7

4.1.2.8 Variable 8

Esta variable categórica corresponde a la segmentación del ratio formado por la combinación del plazo de la operación y el importe de la operación.

Si estudiamos este ratio, podemos observar que los casos Default se encuentran muy distribuidos, aunque destaca que en plazos cortos e importes altos existen pocos casos. También, se puede observar que los plazos en los que se suele conceder préstamos suelen ser cada 12 meses, sobre todo a partir de los 24 meses (24, 36, 48, 60...), y que según es mayor ese plazo, el default suele encontrarse en un rango de importe mayor y más acotado.




Figura 4.20 - Identificación del Default respecto al ratio Plazo / Importe de la operación

Tras realizar el trabajo de discretizar el ratio anterior por tramos que ordenen la FDO y la población no esté muy desbalanceada, obtenemos los siguientes gráficos para la nueva variable 7:




Figura 4.21 - Distribución Variable 7




Figura 4.22 - Distribución FDO respecto la Variable 7

Al observarse en la variable anterior bastante igualdad entre los tramos centrales respecto a la FDO, se ha tomado la decisión de juntarlos, obteniendo como resultado la siguiente tabla y gráficos:




Figura 4.23 - Distribución Variable 7 final




Figura 4.24 - Distribución FDO respecto la Variable 7

4.1.3 Variables adicionales

Se han creado y analizado variables adicionales a las anteriores, las cuales no se van a mostrar en el estudio debido a la sensibilidad de los datos.

4.2 Modelo base – Regresión Logística

4.2.1 Filosofía de segmentación para la construcción del modelo base

La división o agrupación de las variables independientes se ha realizado anteriormente con el propósito de:

- Manejar el número de valores (atributos, tramos) por variable de forma más cómoda.
- Mejorar el poder predictivo de la variable (característica).
- Jerarquizar una primera selección de variables con base a su poder de predicción.

Como norma general, se buscan tramos (*buckets*) que tengan un mínimo del 5% de población y que mantengan monotonía de las frecuencias de default observado (FDOs), tanto en la muestra de entrenamiento, como en la muestra de test.

Para la jerarquización de variables, se realiza un análisis bivalente a partir de los indicadores de la capacidad discriminante que se describen a continuación:

- **WOE** (*Weight Of Evidence*) [13]: es una medida del poder discriminante de cada tramo de la variable, con la que se evalúa la proporción de sucesos buenos (no morosos) y sucesos malos (morosos) en el mismo, y la facilidad de la variable para separar dichas poblaciones.
- **IV** (*Information Value*) [14]: indicador de predictividad de la variable objetivo, que se obtiene a partir de los diferentes WOE's de una variable.

A continuación, se describe cómo se utilizan:

- El **WOE** (*Weight Of Evidence*), se calcula a partir de la siguiente expresión:

$$Weight_of_evidence_{attribute} = \log(p_good_{attribute} / p_bad_{attribute})$$

Ecuación 4.1 - WOE (Weight Of Evidence)

Siendo:

- $p_good\ attribute$: Número de sucesos buenos en el tramo sobre el total de buenos de la muestra.
- $p_bad\ attribute$: Número de sucesos malos en el tramo sobre el total de malos de la muestra.

Para definir cada uno de los tramos, se sitúan los puntos de corte que dividen la población en subgrupos englobando un rango de valores determinado. Estos

rangos de valores se ajustan en base al porcentaje de la muestra que debe estar incluido en dicho rango, el sentido económico y relación con la variable *target*.

Como se puede observar, para poder comparar el peso de cada población en el tramo se ha de realizar un cambio de escala. Para ello, se obtienen las proporciones relativas dividiendo el número de malos del tramo entre el número de malos total de la población y análogamente, el número de buenos del tramo entre el número total de buenos de la población.

Una vez hechas comparables ambas poblaciones, tiene mayor poder discriminante aquel tramo en el que las poblaciones sean lo más distante posible. Esto puede suceder por dos motivos:

- Existe una gran concentración de buenos en el tramo en comparación con los malos.
- Existe una gran concentración de malos en el tramo en comparación con los buenos (por lo que el WOE será alto con signo negativo).

Por tanto, cuanto mayor sea el WOE, mayor distancia existirá entre las poblaciones, lo que implica un mayor poder discriminante entre buenos y malos.

- El **IV** (Information Value), se calcula a partir de la siguiente expresión:

$$IV = \sum_{attributes} [(P_{good_{attribute}} - P_{bad_{attribute}}) * WOE_{attribute}]$$

Ecuación 4.2 - IV (Information Value)

Con el Information Value se obtiene el poder discriminante total de la variable agregando los WOE's de todos los tramos de la misma. Se ha de realizar una ponderación para ajustar según el peso de las poblaciones y para que el WOE de tramos con una alta concentración de malos, cuyo valor es negativo, aumenten el nivel del IV.

Se puede considerar que una variable tiene un nivel de predictividad e idoneidad aceptable para entrar en el modelo a partir de un rango de 0.1.

Por lo tanto, cuanto más se distancien las distribuciones de buenos y malos para una variable, su IV será mayor y se podrá concluir que la variable tiene un mayor poder predictivo.

Además, del IV se realizan los siguientes test:

- Resultado **del test de dos muestras de Wilcoxon** Aproximación normal $Pr > Z$. Consiste en comparar la mediana de dos muestras relacionadas y determinar si existen diferencias entre ellas. Se utiliza como alternativa a la prueba t de Student cuando no se puede suponer la normalidad de dichas muestras.
- Resultado del **test de Kruskal-Wallis** $Pr > \text{Chi-Cuadrado}$. El test de Kruskal-Wallis es un método no paramétrico, para probar si un grupo de datos proviene de la misma población. Al ser una prueba no paramétrica, ésta no asume normalidad en los datos, en oposición al tradicional método de ANOVA.

Posteriormente, tras realizar el análisis bivalente, se genera una matriz de correlaciones. En dicha matriz se puede observar las relaciones entre las variables continuas.

La matriz de correlaciones se genera estimando el coeficiente de correlación de Pearson para cada par de variables. Este coeficiente es un índice estadístico que mide la relación lineal entre dos variables cuantitativas.

El cálculo del coeficiente de correlación lineal se realiza dividiendo la covarianza por el producto de las desviaciones estándar de ambas variables:

$$\text{Pearson} = \frac{\sigma_{XY}}{\sigma_X * \sigma_Y}$$

Ecuación 4.3 - Coeficiente de Pearson

Siendo:

- σ_{XY} = la covarianza de (X, Y)
- σ_X y σ_Y = las desviaciones típicas de las distribuciones marginales.

El valor del índice de correlación varía en el intervalo [-1, +1]. Cuanto más se acerque a 1 en valor absoluto, mayor dependencia existe entre las dos variables. Si el índice de correlación es próximo a 1, cuando una de ellas aumenta, la otra también lo hace en idéntica proporción.

En el caso de que existan variables correlacionadas con más de un determinado porcentaje en valor absoluto (para el estudio se ha usado el 70%) se escoge la que disponga de mejores resultados en el análisis bivalente descartando las demás, ya que si se introdujeran variables correlacionadas aportarían ruido al modelo.

Tras la realización de dichos análisis se descartan variables del estudio por criterios estadísticos y por criterio experto.

Los criterios para el descarte de las variables en esta fase desde el punto de vista estadístico fueron:

- Variables con un IV inferior a 0,1.
- Las variables cuyos estadísticos o p-valores no rechazan la igualdad de las muestras de mejores (buenos) y peores (malos) dado el nivel de confianza impuesto (95%).
- Variables con un porcentaje de valores ausentes superior al 30%.
- Variables con un coeficiente de correlación superior al 70%.

Estos criterios no son absolutamente determinantes. Mediante el trameado de variables se persigue conseguir un mayor poder discriminante y, por tanto, el estudio del análisis bivalente realizado es útil como un primer filtro.

Posteriormente, para las variables candidatas que no han sido rechazadas por los criterios descritos, si éstas son continuas, se generan distintos trameados definiendo los percentiles de la variable como puntos de corte dentro del trameado y se calcula el Information Value (IV) para cada uno de los tramos generados, eligiéndose aquel de mayor IV en el que la tasa de mora no pierde monotonía.

Desde el punto de vista experto, se descartaron variables que:

- Resultaban redundantes.
- No tenían sentido económico en el análisis de reactivo de consumo para particulares.
- Su interpretación resultaba compleja.

4.2.2 *Variables finalistas del modelo base*

Cumpliendo con los requisitos anteriores, ordenamos por IV las variables candidatas a la regresión logística y otros modelos de Machine Learning

Finalmente, tras ejecutar una regresión logística (GLM) mediante el método *stepwise* y testando los resultados con el set de test, el mejor modelo parsimonioso construido con el modelo top en problemas de *Credit Scoring* recoge un **ROC de 76,6%** (valor bastante aceptable a partir de un 70% y cuanto más se acerque al 100%, mejor).




Figura 4.25 - Gráfico d la curva ROC del modelo base en el set de entrenamiento (GLM)

Como se ha podido observar en todas las variables que intervienen en el modelo, disponen de p-valor inferior al 5%, y los estimadores (betas) son consistentes, es decir, su ordenamiento es consecuente con el sentido económico de las variables.

Si observamos las correlaciones mediante la **V de Cramer**², podemos observar que ninguna variable está muy correlacionada con el resto, tomando como referencia a partir del 40% como una correlación moderada.

² La V de Cramer es una corrección que se puede aplicar al coeficiente Chi Cuadrado, lo cual permite obtener un índice con valor máximo (que indica la mayor asociación entre variables) igual a 1 (el valor mínimo es 0, que indica NO asociación).




Figura 4.26 - Correlación V de Cramer entre las variables independientes del modelo base

Respecto a la validación del modelo con el set de test, se ha obtenido, prediciendo con el modelo anterior, un ROC del 75,2%, bastante similar al obtenido con el set de entrenamiento.




Figura 4.27 - Gráfico de la curva ROC del modelo base en el set de test (GLM)

4.3 Modelos avanzados

Partiendo como referencia con un **ROC de 76,6% del modelo base**, vamos a tratar de poner a prueba dicho modelo con otro tipo de modelos avanzados de *Machine Learning*. Para ello, primero se ha realizado un ejercicio partiendo de las mismas variables utilizadas en el modelo base, y un segundo ejercicio, seleccionando combinaciones con otras variables adicionales al modelo base.

4.3.1 Mismas variables que el modelo base

Se modeliza con las mismas variables finalistas del modelo base.

4.3.1.1 Análisis Discriminante Lineal (LDA)

Hemos puesto a prueba el modelo de análisis discriminante lineal (LDA), el cual, quizás no se pueda considerar un modelo avanzado, aunque para esta tipología de problemas suele funcionar bastante bien.

En primer lugar, vamos a realizar una descripción de los valores y ajustes realizados para su entrenamiento:

- **Semilla:** Hemos fijado la semilla para su posible réplica en 17.
- **Control:** Se ha fijado una validación cruzada de 10 pliegues y 5 repeticiones.
- **Métrica:** El modelo se evalúa mediante la métrica ROC.

Respecto a los resultados obtenidos mediante este modelo, podemos observar a continuación que son bastantes similares al modelo base, aunque no lo superan.

ROC	Sensibilidad	Especificidad
76,23%	71,27%	65,50%

Tabla 4.6 - Evaluación del modelo LDA (ROC)

Con estos resultados, se obtiene la siguiente una matriz de confusión:

Predicción	Referencia	
	NO	SI
NO	24.395	803
SI	9.824	1.497

Tabla 4.7 - Matriz de confusión del modelo LDA

Si graficamos el ROC obtenido en el entrenamiento del modelo:




Figura 4.28 - Gráfico de la curva ROC del modelo LDA en el set de entrenamiento

Si validamos el modelo entrenado en el set de test, verificamos que el ROC que se obtiene de 74,62% es bastante similar al alcanzado en el entrenamiento, con lo que nuestro modelo no sobreajusta. A continuación, graficamos la curva ROC obtenida:




Figura 4.29 - Gráfico de la curva ROC del modelo LDA en el set de test

4.3.1.2 Random Forest (RF)

Como se ha descrito con anterioridad, el modelo Random Forest es uno de los modelos avanzados de *ML* en el que se suele obtener grandes resultados en problemas de clasificación. Veamos a continuación cómo se comporta con las variables finalistas del modelo base y si conseguimos superar su predictividad.

En primer lugar, vamos a realizar una descripción de los valores y ajustes realizados para su entrenamiento:

- **Semilla:** Hemos fijado la semilla para su posible réplica en 17.
- **Control:** Se ha fijado una validación cruzada de 10 pliegues y 5 repeticiones.
- **Métrica:** El modelo se evalúa mediante la métrica ROC.
- **Parámetros:**
 - **mtry:** Se ha probado diferentes combinaciones del número máximo de variables utilizadas en cada partición. En este caso, se han utilizado de 5 a 7.
 - **ntree:** Se ha fijado el número de árboles en 500.
 - **maxnodes:** Se ha establecido 10 como número máximo de nodos en el árbol.

Respecto a los resultados obtenidos mediante este modelo, podemos observar que los resultados son bastantes peores de los esperado con las variables del modelo base. El máximo ROC obtenido ha sido de 51,11% y la especificidad siempre ha sido 0, con lo que este modelo siempre predice que NO se va a incumplir.

mtry	ROC	Sensibilidad	Especificidad
5	51,10%	100%	0%
6	50,96%	100%	0%
7	50,94%	100%	0%

Tabla 4.8 - Evaluación del modelo RF (ROC)

Tuning RF on separate dummies




Figura 4.30 - Gráfico del ROC obtenido respecto al número de variables del modelo RF




Figura 4.31 - Gráfico de la curva ROC del modelo RF en el set de entrenamiento

Debido a la mala predictividad del modelo, decidimos obviar la comprobación en el set de test. Pensamos que la mala predictividad obtenida es debida a la poca granularidad que tienen las variables, ya que, al ser variables discretas construidas con pocos segmentos, el algoritmo no funciona correctamente.

4.3.1.3 Máquina Vector Soporte (SVM)

SVM es otro de los algoritmos más sonados para mejorar la predicción del modelo base. En este caso, para su correcto ajuste, se deben de seguir varios pasos de alto coste computacional para llegar a una conclusión.

En primer lugar, para poder identificar en el rango en el que se encuentran los parámetros que hacen que nuestro modelo sea óptimo respecto la métrica fijada, se ha lanzado un modelo con las siguientes especificaciones:

- **Semilla:** Hemos fijado la semilla para su posible réplica en 17.
- **Control:** Se ha fijado una validación cruzada de 10 pliegues y 5 repeticiones.
- **Métrica:** El modelo se evalúa mediante la métrica ROC.
- **Método:** *svmRadial*.

En segundo lugar, tras haber obtenido una ligera idea de donde se encuentran los parámetros *C* y *Sigma* que maximizan el ROC de nuestro modelo, entrenamos un nuevo modelo pasando un *grid* de parámetros a probar:

- **Parámetros:**
 - **sigma:** Toma tres valores (0.01, 0.015, 0.2).
 - **C:** Toma 5 valores (1.75, 1.9, 2, 2.1, 2.25).

Tras su ejecución con las variables finalistas del modelo base, obtenemos de nuevo, unos resultados malos, donde el mejor ROC obtenido no supera el 54,85%. A continuación, mostramos los resultados poco prometedores:

sigma	C	ROC	Sens	Spec
0.010	1.75	37,20%	100%	0%
0.010	1.90	53,00%	100%	0%
0.010	2.00	54,85%	100%	0%
0.010	2.10	54,85%	100%	0%
0.010	2.25	54,85%	100%	0%
0.015	1.75	51,73%	100%	0%
0.015	1.90	53,00%	100%	0%
0.015	2.00	54,85%	100%	0%
0.015	2.10	54,85%	100%	0%
0.015	2.25	54,85%	100%	0%
0.200	1.75	51,73%	100%	0%
0.200	1.90	53,00%	100%	0%
0.200	2.00	54,85%	100%	0%
0.200	2.10	54,85%	100%	0%
0.200	2.25	54,85%	100%	0%

Tabla 4.9 - Evaluación del modelo SVM (ROC)

Al igual que en el caso anterior (RF), se ha obviado mostrar los resultados de la predicción en el set de test debido a los malos resultados obtenidos en el entrenamiento del modelo.

4.3.1.4 Ada Boost

Ada boost es otro de los algoritmos de Ensemble más comunes en este tipo de problemas de clasificación.

Para su correcto entrenamiento, describimos las especificaciones del modelo con mayor ROC logrado en base a este algoritmo:

- **Semilla:** Hemos fijado la semilla para su posible réplica en 17.
- **Control:** Se ha fijado una validación cruzada de 10 pliegues y 5 repeticiones.
- **Métrica:** El modelo se evalúa mediante la métrica ROC.
- **Método:** *ada*.
- **tuneLength:** número de valores aleatorios para C igual a 10
- **Parámetros:**
 - **Maxdepth:** Se ha probado con 3 tipos diferentes de profundidad máxima de los árboles (3, 5, 7).
 - **nu:** Se ha probado 3 valores diferentes (0.01, 0.1, 0.5).
 - **Iter:** Se ha utilizado 3 tipos diferentes de valores (50, 100, 150).

En la siguiente tabla, se describen los resultados obtenidos para las combinaciones probadas:

nu	maxdepth	iter	ROC	Sens	Spec
0,01	3	50	52,77%	100,00%	0,00%
0,01	3	100	63,24%	100,00%	0,09%
0,01	3	150	70,05%	100,00%	0,48%
0,01	5	50	55,75%	99,98%	0,79%
0,01	5	100	65,38%	99,98%	0,87%
0,01	5	150	71,68%	99,98%	0,87%
0,01	7	50	58,51%	99,96%	1,00%
0,01	7	100	66,19%	99,95%	0,92%
0,01	7	150	73,13%	99,94%	0,92%
0,1	3	50	75,33%	99,94%	0,83%
0,1	3	100	76,18%	99,89%	1,35%
0,1	3	150	76,39%	99,89%	1,53%
0,1	5	50	76,09%	99,95%	1,00%
0,1	5	100	76,41%	99,94%	1,14%
0,1	5	150	76,44%	99,92%	1,14%
0,1	7	50	75,46%	99,89%	1,18%
0,1	7	100	75,68%	99,88%	1,35%
0,1	7	150	75,61%	99,88%	1,27%
0,5	3	50	76,59%	99,85%	1,62%
0,5	3	100	76,74%	99,92%	1,27%
0,5	3	150	76,83%	99,92%	1,14%
0,5	5	50	75,81%	99,89%	1,70%
0,5	5	100	75,75%	99,92%	1,48%
0,5	5	150	75,66%	99,92%	1,35%
0,5	7	50	74,73%	99,74%	2,01%
0,5	7	100	74,48%	99,75%	1,79%
0,5	7	150	74,15%	99,75%	1,83%

Tabla 4.10 - Evaluación del modelo Ada Boost (ROC)




Figura 4.32 - Gráfico de la curva ROC respecto sus parámetros en el modelo Ada Boost

Observando los resultados obtenidos con el modelo Ada Boost denotamos un ROC similar al del modelo base, pero con una gran diferencia, la especificidad es muy baja, con lo que este modelo ajustado no sería una buena alternativa para nuestro problema.

4.3.2 Combinación de diferentes variables adicionales al modelo base

En vista a los malos resultados obtenidos en los modelos avanzados de ML con las variables finalistas del modelo base, en esta sección, intentaremos poner a prueba diferentes modelos avanzados con la combinación de nuevas variables.

4.3.2.1 Random Forest (RF)

El modelo de Random Forest es un método de clasificación basado en la realización de múltiples árboles de decisión sobre muestras de un conjunto de datos. Hacemos muchas clasificaciones con menos variables y menos observaciones y al final nos quedamos con un promedio de estas clasificaciones, esa sería la idea a grandes rasgos. La característica que hace de este método muy interesante es la posibilidad de incluir un gran número de

variables input en nuestro modelo ya que no encontraremos relaciones lineales entre ellas y tampoco aparecerán relaciones debidas al azar.

Una funcionalidad que nos da Random Forest en R, es determinar cuáles variables cuantitativas son las más influyentes sobre la variable dependiente. Para ello, vamos a describir las opciones empleadas:

- **ntree:** Nos permite especificar el número de árboles a realizar (500).
- **importance:** Incluir en el objeto las medidas de importancia (TRUE).
- **maxnodes:** Indica el número máximo de nodos de nuestros árboles (10).
- **mtry:** Indica el número máximo de variables en los modelos creados (17)




Figura 4.33 - Importancia de las variables del modelo RF en base al índice de Gini

Como se puede observar en el gráfico anterior, las dos variables más influyentes en nuestro modelo son:

- Var_X1: Variable relacionada con la morosidad del cliente antes de la fecha de formalización.
- Var_X2: Indicador (variable dicotómica) relacionado también con la morosidad del cliente antes de la fecha de formalización.

Tras analizar el peso de las variables en el modelo, se procede a entrenar un modelo tuneado con las siguientes especificaciones:

- **Semilla:** Hemos fijado la semilla para su posible réplica en 17.
- **Control:** Se ha fijado una validación cruzada de 10 pliegues y 5 repeticiones.
- **Métrica:** El modelo se evalúa mediante la métrica ROC.
- **Método:** *rf*.
- **tuneLength:** número de valores aleatorios para C igual a 10
- **Parámetros:**
 - **mtry:** Indica el número máximo de variables en los modelos creados (4, 8, 12, 16).
 - **ntree:** Se ha fijado el número de árboles en 500.
 - **maxnodes:** Se ha establecido 10 como número máximo de nodos en el árbol.

Tuning RF on separate dummies




Figura 4.34 - ROC alcanzado respecto al número de selectores fijados

Tras el entrenamiento del modelo hemos recogido unos resultados poco prometedores, donde el ROC se sitúa lejos del modelo base:

mtry	ROC	Sens	Spec
4	61,23%	100,00%	0,00%
8	62,09%	100,00%	0,00%
12	62,14%	100,00%	0,00%
16	61,75%	99,99%	0,07%

Tabla 4.11 - Evaluación del modelo RF (ROC)

Otra funcionalidad que nos aporta el paquete *randomForest*, es la forma de encontrar el valor óptimo del parámetro *mtry* con la función *tuneRF*. En este caso, la función nos arroja 4 variables como la opción óptima. Como podemos observar, la manera de llegar al parámetro óptimo puede ser variada.




Figura 4.35 - Gráfico resultado de la estimación óptima y automática del parámetro *mtry*

4.3.2.2 *RPART* (CART: Classification And Regression Trees)

Poniendo a prueba un método de particionamiento recursivo basado en árboles (CART), hemos llegado a unos resultados razonables, con un máximo ROC de 73%. Aun obteniendo resultados aceptables, siguen estando por debajo del modelo base al que nos habíamos propuesto batir.

Al igual que en casos anteriores, describimos las especificaciones del modelo con mayor ROC logrado en base a este algoritmo:

- **Semilla:** Hemos fijado la semilla para su posible réplica en 17.
- **Control:** Se ha fijado una validación cruzada de 10 pliegues y 5 repeticiones.
- **Métrica:** El modelo se evalúa mediante la métrica ROC.

- **Método:** *rPart*.
- **tuneLength:** número de valores aleatorios para C igual a 10

En la siguiente tabla, se describen los resultados obtenidos para las combinaciones probadas:

C	ROC	Sensibilidad	Especificidad
0	72,09%	98%	9%
8,79E-05	72,44%	98%	9%
1,10E-04	72,48%	98%	9%
1,46E-04	72,69%	98%	8%
2,64E-04	72,91%	99%	7%
3,51E-04	72,97%	99%	6%
3,66E-04	73,00%	99%	6%
4,88E-04	71,48%	99%	5%
1,05E-03	60,37%	100%	1%

Tabla 4.12 - Evaluación del modelo RPART (ROC)




Figura 4.36 - ROC versus el parámetro C (Complejidad)

Si predecimos con el mejor modelo encontrado sobre la muestra de entrenamiento, obtenemos un ROC de 76,67%, bastante similar al obtenido en el modelo base. Observando la matriz de confusión se denota:

Predicción	Referencia	
	NO	SI
NO	33.988	1.931
SI	146	345

Tabla 4.13 - Matriz de confusión del modelo RPART

En cuanto a su validación en el set de test, hemos conseguido un ROC de 72,45%, aceptable (>70%) pero ligeramente inferior al obtenido en el entrenamiento.




Figura 4.37 - Gráfico de la curva ROC del modelo RF en el set de test

Analizando los resultados obtenidos en este algoritmo, se puede concluir que no es un mal método y que ha arrojado unos resultados aceptables, pero sigue sin acercarse al modelo base.

4.3.2.3 Boosted Generalized Linear Model (GLMBoost)

Al igual que en casos anteriores, describimos las especificaciones del modelo con mayor ROC logrado en base a este algoritmo:

- **Semilla:** Hemos fijado la semilla para su posible réplica en 17.
- **Control:** Se ha fijado una validación cruzada de 10 pliegues y 5 repeticiones.
- **Métrica:** El modelo se evalúa mediante la métrica ROC.
- **Método:** *glmboost*.
- **tuneLength:** número de valores aleatorios para C igual a 10

En la siguiente tabla, se describen los resultados obtenidos para las combinaciones probadas:

mstop	prune	ROC	Sensibilidad	Especificidad
188	yes	0,00%	NaN	NaN
194	no	75,34%	100,00%	0,00%
207	no	75,42%	100,00%	0,00%
408	no	76,18%	100,00%	0,15%
435	no	76,25%	100,00%	0,18%
469	no	76,31%	100,00%	0,22%
539	no	76,42%	100,00%	0,27%
777	no	76,63%	100,00%	0,40%
780	no	76,63%	100,00%	0,40%
969	yes	0,00%	NaN	NaN

Tabla 4.14 - Evaluación del modelo GLMBoost (ROC)

Como se puede observar subrayado en verde en la tabla anterior, el mejor ROC obtenido ha sido de 76,63%. No obstante, la especificidad es casi nula, con lo que el algoritmo está prediciendo, en casi la totalidad de los casos, que no existe Default. Con estos resultados, podemos verificar que este algoritmo, con las variables y los parámetros ajustados, no ha conseguido superar a la regresión logística del modelo base.

Si realizamos las predicciones del algoritmo en el set de test, observamos que el ROC que se obtiene es de 75,85%, lo que garantiza que el algoritmo se comporta de manera similar en el set de test.




Figura 4.38 - Gráfico de la curva ROC del modelo GLMBoost en el set de test

4.3.2.4 Ada Boost

Como hemos podido apreciar en el apartado de Estado del arte, el modelo Ada Boost es otro de los candidatos a mejorar nuestro modelo referencia. Esto es debido a su estructura de ensamblado de varios clasificadores débiles.

Antes de mostrar los resultados obtenidos, describimos las especificaciones del modelo con mayor ROC logrado en base a este algoritmo:

- **Semilla:** Hemos fijado la semilla para su posible réplica en 17.
- **Control:** Se ha fijado una validación cruzada de 10 pliegues y 5 repeticiones.
- **Métrica:** El modelo se evalúa mediante la métrica ROC.
- **Método:** *ada*.
- **tuneLength:** número de valores aleatorios para C igual a 10
- **Parámetros:**
 - **Maxdepth:** Se ha probado con 3 tipos diferentes de profundidad máxima de los árboles (3, 5, 7).

- **nu:** Se ha probado 3 valores diferentes (0.1, 0.5, 1).
- **iter:** Se ha utilizado 3 tipos de valores diferentes (50, 100, 150).

En la siguiente tabla, se describen los resultados obtenidos para las combinaciones probadas:

nu	maxdepth	iter	ROC	Sensibilidad	Especificidad
0,1	3	50	77,43%	99,99%	0,62%
0,5	3	50	77,52%	99,81%	2,11%
1	3	50	77,21%	99,93%	1,14%
0,1	5	50	77,76%	99,89%	2,15%
0,5	5	50	77,17%	99,55%	3,87%
1	5	50	75,84%	99,65%	2,77%
0,1	7	50	77,58%	99,84%	2,15%
0,5	7	50	76,11%	99,09%	5,14%
1	7	50	73,82%	98,55%	6,15%
0,1	3	100	77,98%	99,94%	1,41%
0,5	3	100	77,68%	99,77%	2,55%
1	3	100	77,28%	99,89%	1,27%
0,1	5	100	78,16%	99,85%	2,37%
0,5	5	100	77,15%	99,55%	4,00%
1	5	100	75,83%	99,51%	3,25%
0,1	7	100	77,93%	99,80%	2,59%
0,5	7	100	75,96%	99,09%	4,92%
1	7	100	72,98%	98,40%	7,25%
0,1	3	150	78,10%	99,91%	1,85%
0,5	3	150	77,73%	99,78%	2,64%
1	3	150	77,36%	99,88%	1,23%
0,1	5	150	78,26%	99,82%	2,46%
0,5	5	150	77,14%	99,53%	4,04%
1	5	150	75,54%	99,38%	3,82%
0,1	7	150	77,95%	99,79%	2,86%
0,5	7	150	75,88%	99,20%	4,92%
1	7	150	72,77%	98,42%	7,34%

Tabla 4.15 - Evaluación del modelo Ada Boost (ROC)




Figura 4.39 - Gráfico de la curva ROC respecto sus parámetros en el modelo Ada Boost

Después de analizar en detalle los resultados obtenidos con el modelo, se identifica un ROC de 78,26%, superior al modelo base, pero con una especificidad que deja mucho que desear. Podemos comprobar en la matriz de confusión a lo que nos referimos, mucha exactitud a la hora de identificar los NO Default, pero poca precisión en los SI Default.

Predicción	Referencia	
	NO	SI
NO	34.081	2.207
SI	53	69

Tabla 4.16 - Matriz de confusión del modelo Ada Boost (Entrenamiento)

Si verificamos el modelo prediciendo en el set de test, obtenemos un ROC de 77,91%, ligeramente inferior al del entrenamiento y superior al del modelo base. No obstante, contrastando la matriz de confusión denotamos que la especificidad, al igual que en el algoritmo de entrenamiento, sigue estando muy por debajo del modelo base, con lo que se concluye que el modelo base sigue siendo mejor para nuestro objetivo.

Predicción	Referencia	
	NO	SI
NO	8.502	559
SI	17	13

Tabla 4.17 - Matriz de confusión del modelo Ada Boost (Test)




Figura 4.40 - Gráfico de la curva ROC del modelo Ada Boost en el set de test

4.3.2.5 Gradient Boosting (GBM)

Antes de mostrar los resultados obtenidos, describimos las especificaciones del modelo con mayor ROC logrado en base a este algoritmo:

- **Semilla:** Hemos fijado la semilla para su posible réplica en 17.
- **Control:** Se ha fijado una validación cruzada de 10 pliegues y 5 repeticiones.

- **Métrica:** El modelo se evalúa mediante la métrica ROC.
- **Método:** *gbm*.
- **tuneLength:** número de valores aleatorios para C igual a 10.
- **Parámetros:**
 - **interaction.depth:** Se ha probado con 3 tipos diferentes de profundidad máxima de los árboles (1, 5, 9).
 - **n.trees:** Se ha probado con 30 diferentes combinaciones del número de árboles (1:30) * 50.
 - **shrinkage:** Se ha fijado la merma en 0.1.
 - **n.minobsinnode:** Número mínimo de observaciones por nodo en 20.

En la siguiente tabla, se describen los resultados obtenidos para las combinaciones probadas:

shrinkage	interaction.depth	n.minobsinnode	n.trees	ROC	Sensibilidad	Especificidad
0,073	5	7	4307	73%	99%	5%
0,112	3	22	1453	75%	99%	5%
0,113	10	20	2651	71%	99%	6%
0,283	7	19	3061	69%	98%	8%
0,343	9	19	2092	69%	98%	8%
0,369	5	15	219	72%	98%	7%
0,436	7	12	1213	68%	97%	10%
0,543	4	25	4744	67%	97%	10%
0,544	3	18	3112	67%	97%	11%
0,585	7	10	2646	64%	94%	13%

Tabla 4.18 - Evaluación del modelo Gradient Boosting (ROC)

4.3.2.6 Redes Neuronales (RNN)

Para implementar el modelo avanzado de *NNET*, hemos seguido varios pasos en busca de los parámetros óptimos para nuestro algoritmo. En primer lugar, hemos lanzado una primera red neuronal con nuestro set de datos buscando los valores de los parámetros *size* (número de unidades ocultas intermedias) y *decay* (para evitar el sobreajuste).

size	decay
1	0,1

Tabla 4.19 - Parámetros que hacen óptima la Red Neuronal

Fijando los parámetros de la Red Neuronal (1 capa) con los obtenidos en el modelo anterior, lanzamos de nuevo una Red Neuronal con las siguientes especificaciones:

- **Semilla:** Hemos fijado la semilla para su posible réplica en 17.
- **Control:** Se ha fijado una validación cruzada de 10 pliegues y 5 repeticiones.
- **Métrica:** El modelo se evalúa mediante la métrica ROC.
- **Método:** *nnet*.
- **preProcess:** Preprocesado de los datos centrando y escalando.
- **Parámetros:**
 - **size:** Número de capas ocultas (1).
 - **decay:** Desfallecimiento de la mejora para evitar el sobreajuste (0.1).

Tras el entrenamiento del modelo, el mejor resultado obtenido posee un ROC del 74,35%, ligeramente inferior a nuestro modelo base (GLM). Además, si observamos la especificidad obtenida, identificamos un valor de 2,24%, muy por debajo del esperado.

size	decay	ROC	Sensibilidad	Especificidad
1	0,1	74,35%	100,00%	2,24%

Tabla 4.20 - Evaluación del modelo Red Neuronal (1 capa) (ROC)

Si validamos el modelo ajustado sobre el set de test, identificamos un ROC de 75,82%, ligeramente superior al obtenido en el set de entrenamiento.

Predicción	Referencia	
	NO	SI
NO	8.519	572
SI	0	0

Tabla 4.21 - Matriz de confusión del modelo de Red Neuronal (Test)




Figura 4.41 - Gráfico de la curva ROC del modelo de Red Neuronal en el set de test

4.3.2.7 Extreme Gradient Boosting (XGBoost)

Este modelo de Ensemble, en un amplio porcentaje de casos es una de las alternativas más potentes para la clasificación o regresión. Debido a su gran complejidad, computacionalmente es uno de los modelos más costosos.

Antes de entrenar nuestro modelo, vamos a describir las especificaciones utilizadas y sus parámetros:

- **Semilla:** Hemos fijado la semilla para su posible réplica en 17.
- **Control:** Se ha fijado una validación cruzada de 10 pliegues y 5 repeticiones.
- **Métrica:** El modelo se evalúa mediante la métrica ROC.
- **Método:** *xgbTree*.
- **tuneLength:** número de valores aleatorios para C igual a 10.
- **Parámetros:**
 - **nrounds:** Se ha fijado el número máximo de iteraciones en 500.

- **eta:** Se ha probado con 2 valores, 0.01 y 0.1.
- **max_depth:** Máxima profundidad de los árboles (2, 6, 10).

Como resultado del entrenamiento del modelo basado en este 'tuneado' anterior se ha obtenido:

eta	max_depth	gamma	nrounds	ROC	Sensibilidad	Especificidad
0,3457	3	7,0366	188	77,11%	99,77%	2,83%
0,1322	6	8,0186	194	78,26%	99,85%	2,02%
0,3451	7	7,3433	207	74,86%	99,38%	4,83%
0,5415	10	5,6331	408	70,88%	97,58%	10,06%
0,2873	9	7,5207	435	74,02%	98,98%	5,54%
0,4442	9	7,9912	469	73,29%	98,78%	7,07%
0,0565	10	2,4700	539	76,92%	99,74%	2,90%
0,4821	9	3,6828	777	68,58%	96,38%	12,81%
0,5666	7	7,3682	780	67,72%	95,66%	13,58%
0,3649	1	0,4467	969	77,04%	99,84%	2,35%

Tabla 4.22 - Evaluación del modelo XGBoost (ROC)

Enfocándose en el ROC, observamos que este es de 78,26%, ligeramente superior al del modelo base. No obstante, la especificidad obtenida es significativamente baja, lo cual hace descartar este modelo ajustado como el ganador.

Si verificamos la predictividad del algoritmo en la muestra de test, obtenemos un ROC de 78,13%, casi idéntico al de la muestra de entrenamiento, con lo que quiere decir que este algoritmo funciona bien en muestras diferentes a la de entrenamiento.

Predicción	Referencia	
	NO	SI
NO	8.510	562
SI	9	10

Tabla 4.23 - Matriz de confusión del modelo XGBoost (Test)




Figura 4.42 - Gráfico de la curva ROC del modelo XGBoost en el set de test

4.3.2.8 Ensemble

Se ha intentado crear un Ensemble propio de modelos con la combinación de varios algoritmos. En este caso, debido al tiempo que se disponía, sólo se ha podido realizar la combinación de dos métodos, GLM y Ada Boost.

Como en anteriores modelos, el primer paso a realizar ha sido el tuneado de parámetros y especificaciones para entrenar nuestro mejor modelo:

- **Semilla:** Hemos fijado la semilla para su posible réplica en 17.
- **Control:** Se ha fijado el método de remuestreo 'boot' con 25 pliegues.
- **Métrica:** El modelo se evalúa mediante la métrica ROC.
- **Métodos:** *glm* y *ada*.

Los resultados obtenidos son los mostrados a continuación:

Modelo	Método	maxdepth	iter	ROC	Sensibilidad	Especificidad
Ensemble	GLM			76,14%	99,91%	1,18%
Ensemble	Ada Boost	1	50	73,53%	100,00%	0,00%
Ensemble	Ada Boost	1	100	75,58%	100,00%	0,00%
Ensemble	Ada Boost	1	150	76,33%	100,00%	0,00%
Ensemble	Ada Boost	2	50	76,74%	100,00%	0,00%
Ensemble	Ada Boost	2	100	77,55%	100,00%	0,21%
Ensemble	Ada Boost	2	150	77,75%	99,98%	0,64%
Ensemble	Ada Boost	3	50	77,24%	99,98%	0,46%
Ensemble	Ada Boost	3	100	77,75%	99,94%	1,39%
Ensemble	Ada Boost	3	150	77,86%	99,91%	1,70%

Tabla 4.24 - Evaluación del modelo Ensemble propio (ROC)

ROC




Figura 4.43 - Gráfico comparativo del ROC según el modelo dentro del Ensemble

Como se puede apreciar en la tabla de resultados, el ROC obtenido en el caso de *GLM* es cercano al obtenido en el modelo base (también *GLM* pero con otras variables). Por el lado del modelo Ada Boost, nos encontramos mejor ROC que en modelo base. No obstante, si nos fijamos en la especificidad de los modelos, se aprecia cómo es muy deficiente, con lo

que, pensando alienados con negocio, este modelo no valdría al no identificar apenas casos de Default. Además, si estudiamos la correlación entre los dos modelos del Ensemble, identificamos la siguiente matriz de correlación:

Matriz de correlación	GLM	ADA
GLM	100%	79,34%
ADA	79,34%	100%

Tabla 4.25 - Matriz de correlación del Ensemble

La correlación obtenida entre ambos modelos es muy elevada, con lo que no sería idóneo la construcción de un Ensemble con estas características, debido en gran parte, a que la información que identifican los dos modelos sería casi la misma.

5 RESULTADOS

A continuación, resumimos los resultados de los diferentes modelos que hemos ido probando a lo largo del anterior apartado. La manera de evaluar los modelos ha sido mediante la curva ROC, que es la medida de comparación más común que hemos visto en trabajos similares. Adicionalmente, mencionar que los estadísticos utilizados en segundo plano para su evaluación ha sido la especificidad y la sensibilidad. Vemos la siguiente tabla comparativa:

Modelo	Configuración Variables	ROC	Sensibilidad	Especificidad	Comentarios
Ensemble	Ampliado	-	-	-	Sin resolución final
Ada Boost	Ampliado	78,26%	99,82%	2,46%	Mejor ROC obtenido
XGBoost	Ampliado	78,26%	99,85%	2,02%	Alto coste computacional
Ada Boost	Base	76,83%	99,92%	1,14%	
GLM Boost	Ampliado	76,63%	100,00%	0,40%	
GLM (Modelo base)	Base	76,60%	73,54%	66,03%	Mejor modelo obtenido y muy interpretable
LDA	Base	76,23%	71,27%	64,51%	Casi idéntico a GLM
GBM	Ampliado	75,00%	99,00%	5,00%	
RNN	Ampliado	74,35%	100,00%	2,24%	
RPART	Ampliado	73,00%	99,00%	6,00%	
RF	Ampliado	62,14%	100,00%	0,00%	
SVM	Base	54,85%	100,00%	0,00%	Alto coste computacional
RF	Base	51,10%	100,00%	0,00%	

Tabla 5.1 - Tabla comparativo de modelos implementados

El modelo que mejor ROC nos ha arrojado ha sido el modelo Ada Boost, aunque ligeramente superior al modelo base. Adicionalmente, hemos encontrado 3 modelos más que superan al modelo base en su ROC. No obstante, ninguno de ellos ha arrojado una especificidad asumible para nuestro problema. Además, si tuviésemos en cuenta la interpretabilidad de los resultados obtenidos, el modelo base seguiría siendo el referente.

6 CONCLUSIONES

Una vez terminado el estudio y analizados los resultados, llegamos a las siguientes conclusiones:

- a) La **regresión logística** (modelo base de este estudio), dada la naturaleza del problema, las variables disponibles, las necesidades de explicabilidad del modelo (regulatorias y de negocio) y, en definitiva, su buen comportamiento, **sigue siendo el estándar del mercado a batir**.
- b) Únicamente ha sido posible **mejorar el ROC del modelo base** gracias a incrementar la sensibilidad y reducir la especificidad a cotas cercanas a cero. Dada la finalidad de nuestro modelo, **ninguno de los modelos implementados mejora al modelo de regresión logística**.
- c) Se determina que el modelo de *Credit Scoring*, basado en una regresión logística, no es sólo un modelo glm, sino **el trabajo de varios expertos durante meses e incluso años**.
- d) Aunque no se ha conseguido mejorar la predictividad del modelo base con un modelo avanzado de Machine Learning, **no se concluye que la regresión logística sea el mejor modelo**, sino que, con las limitaciones disponibles, no se ha conseguido un modelo que supere al actual.
- e) Al disponer de más de **250 variables** y **carecer de un completo diccionario de datos** que nos describa el contenido de estas, nos hace pensar que aún queda un **amplio trabajo de análisis y explotación de datos**, el cual, podría hacer que nuestros modelos de ML mejorasen notablemente.
- f) Aunque no se ha conseguido superar la predictividad del modelo base, seguimos viendo grandes **limitaciones en los modelos de ML en lo que respecta a explicabilidad**, ya que, sumando la puesta en marcha de GDPR a las normativas anteriormente vigentes, la entidad se ve en la necesidad de poder explicar por qué no concedería el préstamo a un cliente.
- g) Hoy en día, un punto que limita la aplicación de estos modelos en las entidades es el **no entendimiento del modelo por parte de todas las áreas de negocio** involucradas en el ciclo de vida del modelo.
- h) Otras de las limitaciones que habría que poner a prueba en los modelos de ML, sería **el mantenimiento de estos en los sistemas de la entidad**.
- i) Se ha de tener en consideración, no sólo el tiempo de análisis y explotación de los datos, sino el **alto coste computacional** de alguno de los modelos puestos a prueba. Un conocimiento notable del algoritmo y un correcto tuneado de este, reduciría notablemente el tiempo de entrenamiento.

7 TRABAJO FUTURO

Terminado el estudio, se presentan posibles continuaciones del trabajo que podrían tener interés y que podrían llevar a una mejora en el poder predictivo de los modelos.

- a) Análisis de **técnicas computacionales** para automatizar el cálculo y reducir el coste de computación.
- b) **Ampliación de análisis y preprocesado de la información**: Invertir mayor tiempo en los datos utilizando técnicas avanzadas de preprocesado de la información (*feature engineering*, imputación de missings, *Binning*, ...).
- c) **Inferencia de denegados**: Explotar la mayor información sobre las operaciones denegadas e intentar introducirlas en nuestro modelo.
- d) Análisis de la incorporación de **técnicas de Machine Learning en los actuales frameworks** del ciclo de vida de un modelo de crédito en las entidades financieras
- e) **Text mining**: Se podría tratar de incluir tratamiento de textos para mejorar las predicciones. Por ejemplo, se podrían tratar los comentarios de los analistas, campos de texto rellenos por los clientes, información que publica el regulador y el supervisor...
- f) **Datos externos**: Se podría considerar la búsqueda de nuevos datos y nuevas fuentes de información para mejorar las técnicas de Scoring actuales, ya que con los datos y las variables actuales es muy complicado, especialmente para clientes no vinculados con la Entidad.
- g) **GDPR**: Con la puesta en funcionamiento de esta nueva regulación, se debe realizar un estudio de las nuevas limitaciones que aparecen a la hora de tratar e incluir información en nuestros modelos.
- h) Adicionalmente a la modelización, puede realizarse **un estudio de coste oportunidad** y la mejora o empeoramiento de la morosidad en función del uso de diferentes modelos.
- i) Continuar con el trabajo de **Location Intelligence** con información disponible en la entidad o fuera de ella, tratando de identificar poblaciones, áreas, distritos, ... con mayor o menor probabilidad de incumplimiento. *Se comenzó un trabajo combinando información del banco con el INE, pero debido a la sensibilidad de los datos, se pospuso su continuidad para un futuro.*

8 PLANIFICACIÓN

En este apartado se presenta el calendario de tareas que integran el trabajo desarrollado, así como su coste. Como se puede observar, varias tareas se realizan en paralelo. No obstante, el mayor esfuerzo se ha concentrado en la fase de ‘Adquisición y comprensión de los datos’ (70%) y ‘Tuneado de los algoritmos’ (20%).

Introducción de los datos	Junio				
	S1	S2	S3	S4	S5
Conocimiento del negocio					
Análisis situación actual					
Estado del arte					
Adquisición y comprensión de los datos					
Introducción de los datos					
Explotación de los datos					
Construcción de variables					
Binning					
Modelado					
Estudio de algoritmos					
Tuneado de algoritmos					
Entrenamiento					
Validación en test					
Documentación					
Memoria					

Tabla 8.1 - Calendario de trabajo

El resumen de los recursos utilizados y tiempo invertido se muestra a continuación:

Recursos	1
Total horas	225

Tabla 8.2 - Recursos y tiempo invertido

9 ANEXO 1: TECNOLOGÍA UTILIZADA

En este anexo vamos a describir a alto nivel los recursos tecnológicos utilizados:

- Entorno y lenguaje de programación:
 - **SAS:** En la parte de adquisición de los datos se ha tenido que trabajar con SAS para obtener la información de partida.
 - **R:** Para el desarrollo de todo el trabajo, exceptuando la adquisición del dataset de partida, se ha trabajado con R.
- **Librerías R relevantes:**
 - **caret:** Principal librería de modelización y predicción.
 - **ggplot2:** Principal librería de visualización.
 - **ggthemes:** Librería que añade funcionalidad extra a ggplot2, como por ejemplo, temas predeterminados para visualización de gráficos.
 - **VIM:** Librería para visualización y/o imputación de missings.
 - **DescTools:** Colección de funciones estadísticas para describir datos de manera eficiente.
 - **ROCR y pROC:** Librerías utilizadas para visualizar curvas ROC y obtener el AUC, para comparar los modelos entre ellos.
 - **doMC:** Librería que permite paralelizar tareas haciendo un uso eficiente del hardware y software disponible.
- **Especificaciones de software y hardware:**



Figura 9.1 - Especificaciones del hardware y el sistema operativo utilizado

10 BIBLIOGRAFÍA

- [1] A. Turing, Computing Machinery and Intelligence, October 1950.
- [2] B. d. España, Circular 4/2017 -Normas de información financiera pública y reservada, y modelos de estados financieros, 2017.
- [3] REGLAMENTO (UE) 2016/679 DEL PARLAMENTO EUROPEO Y DEL CONSEJO de 27 de abril de 2016.
- [4] S. F. Bryce Goodman, European Union regulations on algorithmic decision-making and a "right to explanation", Oxford, 2016.
- [5] W. Knight, The Dark Secret at the Heart of AI, MIT Technology Review, April 11, 2017.
- [6] CRD IV - Capital Requirements Regulation (CRR) - 575/2013.
- [7] C. M. Iain Brown, An experimental comparison of classification algorithms for imbalanced credit scoring data sets, Expert Systems with Applications, 2012.
- [8] J. H. J. M. H. J. Gang Wang, A comparative assessment of ensemble learning for credit scoring, Expert Systems with Applications, 2011.
- [9] C. L. Y. L. N. L. Yufei Xia, A boosted decision tree approach using Bayesian hyper-parameter optimization for credit scoring, Expert Systems with Applications, 2017.
- [10] B. d. España, «Ejemplo: Construcción de un scoring de concesión basado en un árbol de decisión,» 2006. [En línea]. Available: https://www.bde.es/f/webbde/Agenda/Eventos/06/Nov/Fic/09-B_II_Seminario_BII_GMT-SGA-JPG_Scoring.pdf.
- [11] H.-V. S. B. B. y. L. C. T. Stefan Lessmanna, «Benchmarking state-of-the-art classification algorithms for credit scoring: A ten-year update,» [En línea]. Available: https://www.business-school.ed.ac.uk/waf/crc_archive/2013/42.pdf.
- [12] D. West, «Neural network credit scoring models,» [En línea]. Available: <http://www.sciencedirect.com/science/article/pii/S0305054899001495>.
- [13] «WOE - Weight Of Evidence,» [En línea]. Available: <https://multithreaded.stitchfix.com/blog/2015/08/13/weight-of-evidence/>.
- [14] «IV - Information Value,» [En línea]. Available: <https://multithreaded.stitchfix.com/blog/2015/08/13/weight-of-evidence/>.

